

- Banyak digunakan karena algoritmanya sederhana dan komputasinya efisien (Wilks, 2011).

2. Hierarchical Clustering

- Menyusun struktur hierarki cluster dalam bentuk *dendrogram* dengan pendekatan *agglomerative* (penggabungan bottom-up) atau *divisive* (pemecahan top-down).
- Tidak memerlukan penentuan K di awal, karena jumlah cluster dapat dipilih dengan memotong dendrogram pada level tertentu (Wilks, 2011).

3. DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

- Mengelompokkan titik berdasarkan kepadatan lokal dan mampu mengidentifikasi *noise*.
- Cocok untuk data dengan bentuk cluster tidak sferis.

4. Gaussian Mixture Model (GMM)

- Mengasumsikan data berasal dari campuran beberapa distribusi Gaussian, dan memberikan probabilitas keanggotaan tiap cluster (soft clustering) menggunakan algoritma EM. Dalam penelitian ini, fokus utama adalah penggunaan clustering (misalnya K-Means) pada **ruang laten Autoencoder** untuk membentuk tipologi rezim hujan tahunan.

c. Evaluasi Hasil Cluster

Beberapa indeks validasi internal yang umum digunakan adalah:

1. Silhouette Score

- Diperkenalkan oleh Rousseeuw sebagai cara grafis dan numerik untuk menilai kualitas partisi cluster (Rousseeuw, 1987).
- Menggabungkan informasi jarak rata-rata ke cluster sendiri dan ke cluster tetangga terdekat; nilai rata-rata Silhouette mendekati 1 menandakan pemisahan cluster yang baik.

2. Davies–Bouldin Index (DBI)

- Diperkenalkan oleh Davies dan Bouldin (1979) sebagai ukuran rata-rata “kemiripan terburuk” antarkluster berdasarkan rasio antara sebaran dalam cluster dan jarak antarcentroid.
- Nilai DBI yang lebih kecil menunjukkan pemisahan cluster yang lebih baik.

3. Calinski–Harabasz Index (CH Index)

- Dikenal juga sebagai *variance ratio criterion*, dikembangkan oleh Caliński dan Harabasz (1974).
- Mengukur rasio dispersi antarcluster terhadap dispersi intracluster; nilai CH yang lebih besar mengindikasikan cluster yang lebih kompak dan terpisah.

Indeks-indeks ini digunakan dalam penelitian untuk memilih konfigurasi klaster yang paling sesuai dan menilai apakah tipologi rezim hujan tahunan yang diperoleh cukup baik secara geometris sebelum diinterpretasikan secara klimatologis.

2.2.3 Deep Learning

Deep learning merupakan cabang *machine learning* yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan untuk mempelajari representasi data pada berbagai tingkat abstraksi. Pendekatan ini telah secara luas digunakan di berbagai domain, termasuk pengenalan pola, pemrosesan citra, ucapan, serta analisis data ilmiah seperti genomik dan atmosfer (LeCun et al., 2015). Dalam penelitian ini digunakan dua arsitektur utama yaitu Autoencoder (AE) dan Convolutional Neural Network (CNN).

2.2.3.1 Autoencoder

Autoencoder adalah jaringan saraf yang dilatih untuk merekonstruksi kembali input-nya sendiri, dengan struktur terdiri dari encoder dan decoder. Encoder memetakan vektor input $\mathbf{x} \in \mathbb{R}^d$ ke representasi laten berdimensi lebih rendah $\mathbf{z} \in \mathbb{R}^k$, sedangkan decoder mencoba merekonstruksi $\hat{\mathbf{x}}$ dari $\mathbf{z}$.

$$\mathbf{z} = f_{\theta}(\mathbf{x}), \hat{\mathbf{x}} = g_{\phi}(\mathbf{z})$$

Pelatihan dilakukan dengan meminimalkan *loss* rekonstruksi, misalnya MSE. Hinton dan Salakhutdinov menunjukkan bahwa *deep autoencoder* yang diinisialisasi dengan baik mampu menghasilkan kode berdimensi rendah yang lebih informatif dibanding PCA untuk berbagai jenis data berdimensi tinggi (Hinton et al., 2006).

Dalam penelitian ini, AE digunakan sebagai ekstraktor fitur tak terawasi untuk mempelajari representasi laten dari vektor 36-dasarian per tahun. Representasi laten tersebut kemudian menjadi dasar penerapan algoritma clustering untuk membentuk tipologi rezim hujan tahunan.

2.2.3.2 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) menggunakan operasi konvolusi untuk mengekstraksi fitur lokal dari data. Walaupun banyak dikenal pada pengolahan citra (2D), CNN juga dapat diterapkan pada deret waktu satu dimensi (CNN 1D) dengan menggeser kernel konvolusi sepanjang sumbu waktu (LeCun et al., 2015).

Pada CNN 1D, kernel konvolusi berukuran kecil digeser melintasi deret input sehingga menghasilkan peta fitur yang merepresentasikan pola lokal (misalnya lonjakan curah hujan dalam beberapa hari terakhir). Studi-studi terkini menunjukkan bahwa CNN 1D efektif untuk pemodelan deret waktu meteorologi dan presipitasi, misalnya untuk prakiraan curah hujan dan klasifikasi kejadian hujan ekstrem (Wilks, 2011).

Dalam penelitian ini, CNN 1D digunakan untuk membangun model deteksi/indikasi dini hujan lebat harian berdasarkan rangkaian fitur R1, R3, R5, R7, dan R10 yang dirangkai sebagai input deret waktu.

2.2.4 Perpaduan Autoencoder dan CNN

Perpaduan model dalam konteks penelitian ini merujuk pada pemanfaatan Autoencoder dan CNN dalam satu kerangka analitis yang saling melengkapi, meskipun keduanya bekerja pada blok tujuan yang berbeda. Pendekatan paduan

yang menggabungkan *representation learning* tak terawasi (misalnya AE) dan *supervised learning* (misalnya CNN) telah banyak digunakan untuk meningkatkan kinerja dan interpretabilitas model pada data kompleks (LeCun et al., 2015).

Secara umum, kombinasi AE–CNN dapat dilakukan dengan:

1. Melatih AE untuk mengekstraksi representasi laten, lalu menggunakan representasi ini sebagai input model klasifikasi (misalnya CNN atau jaringan lain); atau
2. Menggunakan AE dan CNN dalam dua blok analisis yang berbeda namun saling mendukung: AE untuk merumuskan struktur atau rezim iklim, dan CNN untuk memprediksi atau mendeteksi kejadian ekstrem yang terkait.


Penelitian ini mengadopsi pendekatan kedua:

- Blok A (AE + clustering): Autoencoder digunakan untuk mereduksi dimensi pola hujan tahunan (36-dasarian) dan menghasilkan representasi laten yang kemudian dikluster menjadi tipologi rezim hujan tahunan.
- Blok B (CNN 1D): CNN 1D digunakan untuk mendeteksi kejadian hujan lebat harian berdasarkan rangkaian fitur akumulasi curah hujan beberapa hari terakhir.

Dengan demikian, seluruh kerangka analisis dapat dipandang sebagai model hybrid deep learning yang memadukan AE (untuk tipologi rezim tahunan) dan CNN 1D (untuk sinyal harian), yang bersama-sama memberikan gambaran dari skala tahunan hingga harian tentang perilaku curah hujan di stasiun.

2.3 Kerangka Pemikiran

Kerangka pemikiran untuk penelitian ini kami sajikan pada Gambar 2.1 berikut.



Gambar 2. 1 Kerangka pemikiran penelitian.

Gambar 2.1 menyajikan kerangka pemikiran dengan uraian sebagai berikut. Kerangka pemikiran penelitian ini berangkat dari fenomena bahwa curah hujan di wilayah maritim seperti Serang memiliki pola yang kompleks, dipengaruhi oleh interaksi monsun, ITCZ, fenomena laut-atmosfer (seperti ENSO dan IOD), serta faktor lokal seperti topografi dan kedekatan dengan laut. Kompleksitas ini membuat pola musim hujan-kemarau di tingkat stasiun tidak selalu mudah dibaca hanya dari tabel atau grafik curah hujan bulanan. Di sisi lain, Stasiun Meteorologi Maritim Kelas I Serang menyimpan deret waktu curah hujan harian yang panjang, tetapi belum tersedia ringkasan pola tahunan dan sinyal harian yang operasional untuk

mendukung perencanaan infrastruktur dan kesiapsiagaan cuaca di kawasan pesisir. Kondisi tersebut menjadi permasalahan utama: data historis yang kaya belum diolah menjadi informasi pola hujan yang ringkas dan mudah digunakan pemangku kepentingan.

Permasalahan ini menimbulkan kebutuhan untuk melakukan analisis pola curah hujan secara lebih sistematis melalui pengelompokan pola (clustering) sehingga dapat dibentuk tipologi rezim hujan tahunan di stasiun. Dengan merepresentasikan deret harian menjadi vektor 36-dasarian per tahun, tiap tahun pengamatan dapat diperlakukan sebagai satu objek yang akan dikelompokkan ke dalam beberapa pola tahunan yang relatif homogen. Pengelompokan ini diharapkan menghasilkan gambaran yang lebih eksplisit tentang tipe pola hujan di Serang (misalnya lebih mirip monsunial, ekuatorial, atau lokal), dinamika pergeserannya antar tahun, serta implikasinya terhadap musim tanam dan potensi kejadian hujan lebat. Selain pola tahunan, deret harian juga perlu dianalisis dalam bentuk jendela waktu pendek (R1, R3, R5, R7, R10) untuk mendeteksi kondisi yang mengarah pada hujan lebat, sehingga dibutuhkan model yang mampu mengenali pola deret waktu tersebut.

Dalam konteks itulah deep learning dipandang cocok untuk analisis pola curah hujan. Pendekatan ini memungkinkan pembelajaran representasi secara otomatis dari data berdimensi tinggi dan kompleks, tanpa harus merancang seluruh fitur secara manual. Autoencoder dapat mempelajari representasi laten (kode) dari pola hujan tahunan 36-dasarian, sedangkan Convolutional Neural Network (CNN) 1D mampu mengekstraksi pola lokal dari rangkaian akumulasi hujan harian (R1/R3/R5/R7/R10) yang berhubungan dengan kejadian hujan lebat. Dengan demikian, deep learning ditempatkan sebagai jembatan antara deret waktu curah hujan yang mentah dan informasi pola yang lebih mudah diinterpretasikan, baik di skala tahunan maupun harian.

Peran Autoencoder dalam kerangka ini adalah melakukan representasi, ekstraksi fitur, dan reduksi dimensi terhadap pola hujan tahunan. Vektor 36-dasarian tiap tahun dimasukkan ke dalam Autoencoder untuk dipelajari representasi latennya yang berdimensi lebih rendah, namun tetap memuat informasi pola utama.

Ruang laten inilah yang kemudian menjadi dasar penerapan algoritma clustering

(misalnya K-Means) untuk membentuk beberapa kelompok rezim hujan tahunan. Sementara itu, peran CNN adalah mendeteksi kejadian hujan lebat harian. Deret waktu hujan harian diolah menjadi fitur jendela (R1, R3, R5, R7, R10) dan diberi label hujan lebat/tidak berdasarkan ambang persentil musiman (P95–P99). CNN 1D kemudian dilatih untuk mengenali pola jangka pendek yang membedakan hari-hari dengan hujan lebat dari hari-hari biasa, sehingga menghasilkan sinyal deteksi/indikasi dini di tingkat stasiun.

Tahap berikutnya adalah integrasi Autoencoder dan CNN dalam satu kerangka analitis. Di satu sisi, blok Autoencoder + clustering menghasilkan tipologi rezim hujan tahunan yang stabil dan dapat diinterpretasikan untuk menjelaskan variasi pola hujan antar tahun di Stasiun Meteorologi Maritim Serang. Di sisi lain, blok CNN 1D menghasilkan model deteksi hujan lebat harian yang dievaluasi dengan metrik POD, FAR, CSI, dan AUROC sehingga layak dipertimbangkan sebagai prototipe sinyal operasional. Integrasi kedua blok ini menghasilkan ****output penelitian**** berupa: (1) tipologi rezim hujan tahunan beserta tren kemunculannya yang dapat digunakan dalam komunikasi musim dan pengelolaan sumber daya air, dan (2) prototipe sinyal deteksi/indikasi dini hujan lebat harian yang sederhana dan siap dioperasikan di level stasiun. Selain memberikan manfaat praktis bagi stasiun, kerangka ini juga berkontribusi pada pengembangan aplikasi deep learning di bidang Teknik Informatika untuk analisis deret waktu curah hujan.

BAB III

METODOLOGI PENELITIAN

Bab ini menjelaskan kebutuhan penelitian, rancangan teknis tahapan penelitian, serta teknik analisis dan evaluasi model yang digunakan untuk menjawab rumusan masalah terkait pembentukan tipologi rejim hujan tahunan dan pengembangan sinyal deteksi/indikasi dini hujan lebat di Stasiun Meteorologi Maritim Serang.

3.1 Analisis Kebutuhan

Subbab ini menguraikan kebutuhan penelitian dari sisi dataset, atribut/fitur/label, populasi dan sampel, serta metode pengumpulan data.

3.1.1 Dataset dan sumber data

Data utama yang digunakan dalam penelitian ini adalah data curah hujan harian di Stasiun Meteorologi Maritim Kelas I Serang dengan periode pengamatan sekitar 30 tahun, yaitu dari 1995 hingga 2024. Data tersebut diperoleh dari arsip klimatologi internal BMKG (Stasiun Meteorologi Maritim Serang) yang telah melalui prosedur pencatatan operasional standar. Secara umum, struktur dataset harian dapat dinyatakan sebagai berikut.

- Tanggal pengamatan (format: YYYY-MM-DD)
- Curah hujan harian (mm)

Data bersifat deret waktu titik (station-based) sehingga setiap baris mewakili satu hari pengamatan di stasiun tersebut.

3.1.2 Atribut, Fitur, dan Label

Atribut dasar yang digunakan dalam penelitian ini berupa tanggal pengamatan (tahun, bulan, hari) dan curah hujan harian dalam satuan milimeter (mm). Data curah hujan kemudian diturunkan menjadi sejumlah fitur yang relevan untuk dua blok analisis sebagaimana telah kami sajikan pada Gambar 2.1, yaitu

pembentukan tipologi rejim hujan tahunan (Blok A) dan pengembangan sinyal deteksi/indikasi dini hujan lebat harian (Blok B).

Untuk Blok A, fitur utama yang digunakan adalah akumulasi curah hujan per dasarian (10 harian). Dalam praktik klimatologi di Indonesia, dasarian digunakan sebagai satuan analisis yang menyeimbangkan kebutuhan resolusi temporal dengan peredaman fluktuasi harian. Satu tahun dibagi menjadi 36 dasarian ($3 \text{ dasarian} \times 12 \text{ bulan}$), sehingga pola curah hujan tahunan pada suatu stasiun dapat direpresentasikan sebagai vektor berdimensi 36 yang memuat akumulasi curah hujan pada masing-masing dasarian. Representasi seperti ini lazim digunakan dalam kajian pola hujan untuk mengidentifikasi rejim hujan tahunan dan pergeseran musim (BMKG, 2020a). Dalam blok ini, proses bersifat tak terawasi (unsupervised) sehingga tidak ada label eksternal; setiap tahun akan dikelompokkan ke dalam klaster berdasarkan kedekatan representasi laten yang dipelajari oleh Autoencoder.

Untuk Blok B, fitur difokuskan pada karakter deret waktu jangka pendek yang relevan dengan kejadian hujan lebat. Dari deret curah hujan harian, dibentuk fitur akumulasi jendela waktu seperti R1, R3, R5, R7, dan R10, yang masing-masing merepresentasikan jumlah curah hujan 1, 3, 5, 7, dan 10 hari terakhir hingga hari ke- t . Pendekatan jendela seperti ini umum digunakan dalam model *time series* untuk curah hujan dan hidrologi karena mampu menangkap akumulasi hujan yang berperan pada kejadian ekstrem (Ishida et al., 2024).

Label (target) untuk Blok B berupa variabel biner yang menandai apakah terjadi kejadian hujan lebat pada hari ke- t atau tidak. Secara operasional, BMKG dan berbagai sumber merujuk klasifikasi intensitas hujan harian, misalnya hujan ringan (0,5–20 mm/hari), hujan sedang (20–50 mm/hari), dan hujan lebat ketika curah hujan harian melampaui sekitar 50 mm/hari. Pada penelitian ini, definisi kejadian hujan lebat dipertajam dengan pendekatan ambang persentil musiman, di mana hari-hari dengan curah hujan melebihi persentil ke-95 hingga ke-99 (P95–P99) dari distribusi hujan harian pada musim yang sama dikategorikan sebagai kejadian ekstrem. Pendefinisian ekstrem berbasis persentil banyak digunakan dalam studi iklim ekstrem karena lebih adaptif terhadap karakter lokal dan tidak bergantung pada satu nilai ambang absolut yang seragam (Wilks, 2011).

3.1.3 Populasi, Sampel, dan Teknik Sampling

Populasi konseptual penelitian ini adalah seluruh deret waktu curah hujan harian yang dapat diamati di Stasiun Meteorologi Maritim Serang sejak stasiun beroperasi hingga saat ini. Sampel penelitian dibatasi pada data curah hujan harian periode 1995–2024 yang tersedia dan memenuhi kriteria mutu dasar sebagaimana dijelaskan pada Subbab 3.1.4.

Untuk pembentukan tipologi rejim hujan tahunan, unit analisis adalah tahun, sehingga jumlah sampel setara dengan jumlah tahun pengamatan yang lolos seleksi mutu. Untuk pengembangan sinyal deteksi/indikasi dini hujan lebat, unit analisis adalah jendela deret waktu harian yang dibentuk dari kombinasi fitur R_1 , R_3 , R_5 , R_7 , dan R_{10} beserta label kejadian hujan lebat/tidak pada hari ke- t . Pendekatan ini sejalan dengan praktik umum pada pemodelan deret waktu curah hujan menggunakan *deep learning*, di mana setiap jendela deret waktu diperlakukan sebagai satu contoh pelatihan (training example) (Sari et al., 2020).

Teknik sampling yang digunakan untuk pemodelan CNN 1D adalah *time-aware split*, yaitu pemisahan data ke dalam data latih, validasi, dan uji berdasarkan periode waktu, bukan pemilihan acak murni. Pendekatan ini dianjurkan dalam pemodelan deret waktu agar informasi masa depan tidak tercampur ke proses pelatihan model (Wilks, 2011). Secara umum, penelitian ini menggunakan proporsi sekitar 60% data awal sebagai data latih, 20% periode berikutnya sebagai data validasi, dan 20% periode terakhir sebagai data uji, dengan tetap memperhatikan kecukupan jumlah kejadian hujan lebat di masing-masing himpunan.

3.1.4 Metode pengumpulan dan pra-pemrosesan data

Data curah hujan harian diperoleh dari arsip klimatologi Stasiun Meteorologi Maritim Serang/BMKG melalui prosedur ekstraksi data historis yang telah digunakan secara rutin dalam penyusunan informasi iklim. Tahapan pengumpulan meliputi penarikan data dari basis data internal atau file historis, pengecekan kesesuaian format tanggal dan satuan curah hujan (mm), serta verifikasi rentang waktu pengamatan. Praktik ini sejalan dengan pedoman penanganan data iklim yang menekankan pentingnya konsistensi format dan kelengkapan deret waktu sebelum digunakan untuk analisis statistik lanjutan.