

BAB II

LANDASAN TEORI DAN KERANGKA PEMIKIRAN

2.1 Tinjauan Pustaka

2.1.1 Studi tentang pola dan rezim hujan

Kajian tentang pola dan rezim curah hujan di kawasan Asia Tenggara–Maritim telah lama menunjukkan bahwa wilayah ini didominasi oleh pola monsun dengan perbedaan jelas antara rezim hujan musim panas dan musim dingin di belahan bumi utara dan selatan khatulistiwa. Chang et al. (2005) menguraikan siklus tahunan curah hujan Asia Tenggara berdasarkan kombinasi faktor sirkulasi monsun dan konveksi laut–daratan, dan menunjukkan adanya perbedaan rezim hujan boreal summer dan boreal winter yang memengaruhi distribusi curah hujan bulanan sepanjang tahun.

Di tingkat regional yang lebih sempit, penelitian terdahulu memanfaatkan indeks musim (seasonality index) untuk mengklasifikasikan rezim hujan menjadi beberapa kelas, mulai dari sangat merata hingga sangat musiman, misalnya pada kajian tentang zona iklim Borneo (Sa’adi et al., 2021). Penelitian tersebut membagi rezim curah hujan menjadi tujuh kelas berdasarkan nilai indeks musim, sehingga setiap wilayah dapat dikaitkan dengan karakteristik “sangat merata”, “musiman dengan musim kering pendek”, hingga “sangat musiman dengan satu musim hujan dominan.”

Kajian klimatologi kawasan Indonesia juga menekankan bahwa sebagian besar wilayah memiliki rezim hujan monsunial dengan satu atau dua puncak hujan, dan bahwa informasi tentang pola tahunan ini penting untuk keperluan perencanaan sektor pertanian, sumber daya air, dan kebencanaan (Gunawan, 2006). Namun, sebagian besar kajian tersebut masih berfokus pada deskripsi statistik dan pemetaan zona iklim skala luas, bukan pada pengembangan produk tipologi pola tahunan yang terdokumentasi untuk tingkat stasiun tunggal.

2.1.2 Pengelompokan dan regionalisasi curah hujan berbasis klastering

Pendekatan klastering telah banyak digunakan untuk mengidentifikasi pola curah hujan dan mengelompokkan wilayah ke dalam rezim hujan yang homogen. Ahmad Basri et al. (2021) merancang skema regionalisasi rezim hujan menggunakan kombinasi Random Forest dan Bootstrap (hybrid RF-Bs) yang dikombinasikan dengan analisis klaster hierarkis. Mereka menunjukkan bahwa analisis klaster dapat mengungkap pola perilaku rezim hujan di suatu wilayah dengan mengelompokkan titik hujan ke dalam klaster-klaster yang homogen berdasarkan karakteristik curah hujan, sekaligus menurunkan galat Root Mean Square Error (RMSE) dan Mean Absolute Error (MAE) melalui prosedur kombinasi tersebut.

Di Indonesia, penelitian Suryanto (2017) membandingkan pengelompokan curah hujan 15 harian di Provinsi Daerah Istimewa Yogyakarta menggunakan fuzzy c-means dan K-Means. Dengan menggunakan indeks validasi, penelitian ini menyimpulkan bahwa K-Means lebih sesuai untuk pengelompokan pola curah hujan 15 harian di wilayah tersebut dibanding fuzzy c-means, sekaligus mengilustrasikan pentingnya pemilihan indeks validasi yang tepat dalam menilai kualitas hasil klaster. Penelitian lain yang menganalisis curah hujan di Indonesia menggunakan pendekatan klastering deret waktu juga menunjukkan bahwa teknik klaster mampu mengungkap tren dan variabilitas curah hujan pada skala spasial yang luas, misalnya dengan mengelompokkan stasiun-stasiun hujan berdasarkan kemiripan deret waktu curah hujan tahunan (Iskandar et al., 2025).

Di luar Indonesia, berbagai pendekatan klastering deret waktu curah hujan juga dikembangkan. Texeira dkk. mengembangkan metode komputasional untuk

menganalisis deret waktu presipitasi di wilayah Amazon dengan teknik pembelajaran mesin, sehingga pola hujan tahunan di ratusan stasiun dapat dikelompokkan ke dalam pola-pola tipikal yang berguna untuk analisis hidrologi dan perencanaan (Texeira, 2025). Studi lain mengevaluasi stabilitas hasil kluster curah hujan ekstrem dan menunjukkan bahwa indeks seperti Silhouette, Davies–Bouldin, dan pengukuran stabilitas berbasis resampling dapat digunakan untuk menilai keandalan struktur kluster yang diperoleh (Mariana et al., 2021).

Secara umum, kajian-kajian tersebut menegaskan bahwa: (1) klastering efektif untuk mengidentifikasi pola curah hujan; (2) pemilihan indeks validasi dan analisis stabilitas kluster sangat krusial; dan (3) sebagian besar studi berfokus pada multi-stasiun atau regional, bukan pada perancangan tipologi pola tahunan yang operasional di satu stasiun tertentu.

2.1.3 Autoencoder untuk data iklim dan deret waktu

Dalam beberapa tahun terakhir, Autoencoder (AE) dan variannya menjadi salah satu pendekatan populer untuk pembelajaran representasi (representation learning) dari deret waktu dan data iklim berdimensi tinggi. Kurihana et al. (2024) mengusulkan pendekatan klasifikasi iklim berbasis clustering autoencoder, yang memanfaatkan AE tak terawasi untuk melakukan reduksi dimensi keluaran model iklim, kemudian mengelompokkan vektor laten tersebut menjadi pola-pola iklim yang bermakna. Studi ini menunjukkan bahwa AE dapat menghasilkan representasi iklim yang lebih informatif dibandingkan teknik reduksi dimensi tradisional seperti PCA, sehingga memudahkan proses klastering pola iklim.

Pada penelitian lain, Ibebuchi (2024) memperkenalkan pendekatan pengelompokan deret waktu fuzzy menggunakan jaringan saraf autoencoder untuk mengelompokkan tipe sirkulasi atmosfer. Autoencoder digunakan untuk mentransformasikan deret waktu tekanan permukaan laut menjadi ruang laten berdimensi rendah yang lebih padat, sehingga proses klastering fuzzy terhadap pola sirkulasi atmosfer dapat dilakukan secara lebih efisien dan tahan terhadap perubahan data. Hasilnya menunjukkan bahwa transformasi nonlinier oleh AE meningkatkan pemisahan kluster dibandingkan jika klastering langsung dilakukan di ruang asli.

Di sisi lain, beberapa penelitian mengembangkan varian Autoencoder khusus untuk data iklim dan deret waktu. Spuler et al. (2025) memperkenalkan metode variational autoencoder (VAE) untuk mengidentifikasi rezim sirkulasi probabilistik yang secara khusus ditargetkan pada pola presipitasi lokal, sehingga rezim yang dihasilkan tidak hanya prediktif tetapi juga informatif terhadap dampak di skala lokal. Nguyen & Quanz (2021) mengusulkan temporal latent auto-encoder yang mampu melakukan faktorisasi nonlinier deret waktu multivariat dan mempelajari representasi laten yang cocok untuk tugas prediksi dan analisis struktur dinamis. Penelitian lain menggunakan graph autoencoder untuk merepresentasikan variabel iklim seperti presipitasi dan suhu dalam struktur graf, sehingga hubungan spasial dan telekoneksi iklim dapat dipertahankan dalam proses pembelajaran representasi (Agarwal et al., 2024).

Secara garis besar, literatur-literatur tersebut menegaskan bahwa Autoencoder dan variannya efektif untuk: (1) melakukan reduksi dimensi data iklim atau deret waktu cuaca; (2) menyediakan vektor laten yang lebih sesuai untuk klustering; dan (3) mengaitkan rezim sirkulasi atau iklim dengan pola presipitasi. Namun, pemanfaatan AE untuk membangun tipologi rezim hujan tahunan pada skala stasiun tunggal dengan representasi berbasis dasarian masih relatif jarang dijumpai.

2.1.4 Deep learning berbasis CNN 1D untuk prediksi curah hujan dan kejadian ekstrem

Convolutional Neural Network satu dimensi (CNN 1D) banyak digunakan untuk mengekstraksi fitur lokal dari deret waktu meteorologi dan hidrologi. Beberapa penelitian secara spesifik menerapkannya pada prediksi curah hujan harian. Sebuah studi tentang prediksi curah hujan harian di Indonesia menggunakan model CNN 1D untuk memprediksi curah hujan hingga 14 hari ke depan berdasarkan data observasi BMKG, dan menunjukkan bahwa CNN 1D mampu menangkap fitur temporal yang relevan untuk prakiraan jangka pendek (Sari et al., 2020). Ponnoprat (2021) mengembangkan model deep learning yang memanfaatkan korelasi jangka pendek dan pola musiman jangka panjang untuk

prakiraan presipitasi harian, dan menemukan bahwa arsitektur berbasis CNN/LSTM dapat mengungguli beberapa model tradisional dalam hal akurasi.

Pengembangan lebih lanjut menggabungkan CNN 1D dengan arsitektur lain. Penelitian Liu et al. (2023) mengusulkan model *nowcasting* intensitas curah hujan berbasis Conv1D–Transformer (RLNformer) yang mengklasifikasikan deret waktu curah hujan ke dalam empat kategori (tidak hujan hingga hujan lebat dan di atasnya). Studi tersebut menunjukkan bahwa kombinasi ekstraksi fitur lokal oleh Conv1D dan pemodelan ketergantungan jangka panjang oleh Transformer dapat meningkatkan akurasi klasifikasi level hujan. Penelitian lain juga menggabungkan *denoising* Autoencoder dengan Convolutional LSTM untuk prediksi cuaca laut global dan menemukan bahwa penghilangan *noise* serta pembelajaran fitur spasio-temporal meningkatkan kinerja prakiraan dibandingkan metode numerik murni (Kim et al., 2020).

Dalam konteks kejadian ekstrem, beberapa penelitian memanfaatkan CNN untuk mengenali pola yang mengarah pada hujan lebat atau peristiwa ekstrem lain. Xie et al. (2023) mengembangkan model CNN dan LSTM untuk prakiraan anomali curah hujan dan kejadian hujan ekstrem dalam skala diperluas, dan menunjukkan bahwa model deep learning mampu memberikan prakiraan yang lebih andal untuk kejadian ekstrem tertentu. Penelitian terbaru yang menggunakan CNN untuk mengidentifikasi kejadian hujan ekstrem berdasarkan variabel dinamika atmosfer tertentu melaporkan bahwa model CNN dapat mengenali sekitar 95% kejadian hujan ekstrem yang diamati, dengan kinerja yang dinilai menggunakan metrik seperti area under ROC curve (AUC) (Mouassom et al., 2025).

Pada penelitian lain, studi terkait bahaya turunan dari kondisi curah hujan ekstrem, seperti prediksi kerentanan longsor dinamis akibat hujan ekstrem, menunjukkan bahwa arsitektur CNN 1D umum yang sering digunakan pada studi kerentanan berbasis hujan dapat ditingkatkan kinerjanya dengan optimasi struktur dan parameter, dan kinerja model diukur menggunakan metrik AUC (Mejia-Manrique et al., 2025). Rangkaian studi ini menegaskan bahwa CNN 1D dan varian *deep learning* terkait sangat relevan untuk tugas deteksi/klasifikasi kejadian berbasis deret waktu pada curah hujan dan indikator meteorologis lainnya.

2.1.5 Sintesis dan posisi penelitian

Dari kajian pustaka pada sub bab 2.1.1 sampai dengan 2.1.4 sebagaimana kami sajikan kembali pada Tabel 2.1, kami merangkum beberapa poin yang menjadi sintesis dan memposisikan penelitian ini berdasarkan penelitian terdahulu.

Tabel 2.1 Kajian penelitian terdahulu.

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
1	Chang et al. (2005)	Siklus tahunan hujan Asia Tenggara–Maritim	Analisis klimatologis & sirkulasi monsun	Asia Tenggara–Maritim	Mengidentifikasi perbedaan rezim hujan boreal summer vs boreal winter	Memberi konteks regional pola hujan monsun yang memengaruhi Serang
2	Sa’adi et al. (2021)	Penentuan zona iklim Borneo berbasis seasonality index	Analisis indeks musim & klastering	Pulau Borneo	Membagi rezim hujan menjadi 7 kelas berdasarkan indeks musim	Menunjukkan cara memampatkan pola tahunan menjadi tipologi rezim
3	Gunawan (2006)	Variabilitas atmosfer dan hujan di Sulawesi	Analisis deret waktu & klimatologis	Sulawesi, Indonesia	Menunjukkan pengaruh ENSO dan faktor lokal terhadap pola hujan	Menegaskan pentingnya informasi pola hujan lokal untuk sektor strategis
4	Basri et al. (2021)	Regionalisasi rezim hujan dengan hybrid RF–Bootstrap	Random Forest, Bootstrap, klaster hierarkis	Wilayah studi (multi-stasiun hujan)	Menghasilkan zonasi hujan homogen dengan galat (RMSE, MAE) yang menurun	Menjadi rujukan pemanfaatan klastering untuk rezim hujan
5	Suryanto (2017)	Pengelompokan curah hujan 15 harian di DIY	K-Means vs fuzzy c-means	Provinsi DI Yogyakarta	K-Means lebih sesuai untuk pola 15 harian dibanding fuzzy c-means	Menguatkan pemilihan K-Means + indeks validasi untuk klastering
6	Iskandar et al. (2025)	Tren dan variabilitas hujan (multi-stasiun)	Analisis deret waktu & statistik hujan	Beberapa stasiun hujan	Mengidentifikasi tren dan variabilitas curah hujan di bawah perubahan iklim	Memberi contoh analisis tren hujan yang bisa dikaitkan dengan tipologi lokal

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
7	Kurihana et al. (2024)	Identifikasi pola iklim dengan clustering autoencoder	Autoencoder + klustering	Data keluaran model iklim	AE menghasilkan representasi laten lebih informatif dari PCA untuk klaster iklim	Landasan penggunaan AE untuk tipologi rezim hujan tahunan
8	Ibebuchi (2024)	Klustering deret waktu fuzzy dengan Autoencoder	Autoencoder + fuzzy time series clustering	Deret waktu sirkulasi atmosfer	AE meningkatkan pemisahan klaster sirkulasi atmosfer	Menunjukkan keunggulan AE untuk klustering deret waktu
9	Spuler et al. (2025)	Rezim sirkulasi probabilistik terkait presipitasi ekstrem	Variational Autoencoder (VAE)	Data iklim & presipitasi lokal	VAE menghubungkan rezim sirkulasi dengan dampak hujan ekstrem lokal	Menginspirasi kaitan ruang laten dengan kejadian hujan ekstrem
10	Sari et al. (2020)	Prakiraan curah hujan harian hingga 14 hari	CNN 1D	Data observasi BMKG (Indonesia)	CNN 1D efektif menangkap pola temporal untuk prakiraan hujan harian	Landasan penggunaan CNN 1D pada deret waktu hujan di Indonesia
11	Ponnopratt (2021)	Prakiraan presipitasi harian dengan seasonally-integrated DL	Autoencoder + CNN/LSTM	Data presipitasi harian	Model DL mengungguli metode tradisional dalam akurasi prakiraan	Menunjukkan potensi kombinasi AE + CNN/LSTM untuk hujan
12	Liu et al. (2023)	Nowcasting level curah hujan dengan Conv1D-Transformer	Conv1D + Transformer (RLNformer)	Xinjiang Utara, Cina	Kombinasi Conv1D-Transformer efektif untuk klasifikasi level hujan	Menguatkan relevansi Conv1D untuk klasifikasi kategori hujan

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
13	Kim et al. (2020)	Prediksi cuaca laut global	Denoising AE + ConvLSTM	Data cuaca laut global	Penghilangan noise + pembelajaran spasio-temporal meningkatkan prakiraan	Menunjukkan manfaat AE + CNN/LSTM pada data atmosfer yang kompleks
14	Xie et al. (2023)	Prakiraan hujan dan kejadian ekstrem jangka menengah	Deep learning (CNN/LSTM)	Cina Timur	Model DL memberikan prakiraan yang cukup andal untuk kejadian hujan ekstrem	Rujukan penggunaan AUROC dalam menilai prakiraan kejadian ekstrem
15	Mariana et al. (2021)	Klaster hujan ekstrem dengan pendekatan robust	RPCA + Tukey's biweight + indeks validasi	Data hujan ekstrem	Menunjukkan pentingnya Silhouette, DBI, dan stabilitas klaster	Menginspirasi evaluasi kualitas-stabilitas klaster dalam penelitian ini

1. Telah terdapat beberapa penelitian terdahulu yang kami temukan terkait dengan rezim curah hujan di wilayah Indonesia maupun Benua Maritim Indonesia, namun umumnya berfokus pada deskripsi pola musiman skala luas atau pembagian zona iklim berdasarkan indeks musim, bukan pada produk tipologi pola tahunan yang ringkas dan terdokumentasi di tingkat stasiun tunggal.
2. Pendekatan klastering curah hujan telah digunakan baik di Indonesia maupun di negara lain untuk mengelompokkan stasiun atau deret waktu curah hujan menjadi beberapa klaster homogen, dan berbagai indeks validasi klaster telah dievaluasi. Meski demikian, aspek stabilitas tipologi antartahun dan integrasinya dengan kebutuhan operasional di stasiun lokal masih relatif jarang dibahas.
3. Autoencoder dan variannya terbukti efektif sebagai alat reduksi dimensi dan pembelajaran representasi laten pada data iklim berdimensi tinggi, serta telah digunakan untuk mengidentifikasi rejim sirkulasi atau pola iklim yang terkait presipitasi. Namun, penerapan AE untuk membangun

tipologi rezim hujan tahunan berbasis vektor dasarian pada satu stasiun hujan, dengan penilaian kualitas dan stabilitas tipologi secara eksplisit, masih sangat terbatas.

4. CNN 1D dan model deep learning sejenis telah dimanfaatkan secara luas untuk prakiraan curah hujan dan identifikasi kejadian hujan ekstrem. Sebagian besar penelitian berfokus pada prakiraan jumlah atau kelas curah hujan pada skala regional, atau pada penggunaan CNN untuk menilai bahaya hujan ekstrem yang luas, dengan metrik seperti AUC, RMSE, dan MAE. Integrasi CNN 1D sebagai penyusun sinyal deteksi/indikasi dini hujan lebat yang dirancang khusus untuk kebutuhan produk di satu stasiun, dengan definisi ekstrem berbasis persentil musiman dan metrik operasional seperti POD, FAR, dan CSI, relatif belum banyak ditelaah.

Berdasarkan kesenjangan tersebut, penelitian ini menempatkan diri pada irisan antara pembentukan tipologi rezim hujan tahunan lokal dan pengembangan sinyal deteksi/indikasi dini hujan lebat berbasis CNN 1D pada tingkat stasiun. Kontribusi utama yang diharapkan adalah: (1) rancangan representasi tahunan berbasis dasarian yang dipelajari dengan Autoencoder untuk menghasilkan tipologi pola curah hujan tahunan yang berkualitas dan stabil pada stasiun tunggal; serta (2) pengembangan model CNN 1D berbasis jendela harian dengan definisi hujan lebat menggunakan persentil musiman, yang dievaluasi menggunakan metrik yang lazim pada sistem peringatan dini (POD, FAR, CSI, AUROC) dan diarahkan untuk mendukung kebutuhan layanan klimatologis di Stasiun Meteorologi Maritim Serang.

2.2 Landasan Teori

Subbab ini menguraikan konsep-konsep dasar yang menjadi fondasi penelitian, mencakup karakteristik curah hujan dan pola iklim di Indonesia, konsep rezim hujan dan representasi dasarian, prinsip pembelajaran representasi dengan Autoencoder, Convolutional Neural Network satu dimensi (CNN 1D) untuk deret waktu, serta teori mengenai klastering dan metrik verifikasi model deteksi hujan lebat.

2.2.1 Curah hujan dan klimatologi Indonesia

Curah hujan merupakan salah satu unsur utama dalam klimatologi yang menggambarkan jumlah air yang jatuh ke permukaan bumi dalam bentuk hujan, biasanya dinyatakan dalam milimeter (mm) per satuan waktu (harian, dasarian, bulanan, dan seterusnya). Dalam konteks iklim tropis Indonesia, variasi utama iklim antarmusim lebih banyak tercermin dari variabilitas curah hujan dibandingkan suhu udara yang relatif konstan sepanjang tahun (Wilks, 2011).

Secara nasional, BMKG menjelaskan bahwa iklim Indonesia ditandai oleh tiga pola utama curah hujan, yaitu pola monsun, ekuatorial, dan lokal (BMKG, 2022).

- Pola monsun memiliki satu puncak musim hujan dan satu musim kemarau yang jelas, sangat dipengaruhi oleh sirkulasi angin monsun Asia–Australia.
- Pola ekuatorial cenderung menunjukkan dua puncak musim hujan (bimodal) yang berkaitan dengan perlintasan Zona Konvergensi Antar Tropik (ITCZ) dua kali dalam setahun.
- Pola lokal lebih kuat dipengaruhi topografi, morfologi pesisir, dan sirkulasi lokal, sehingga puncak hujan tidak selalu mengikuti pola monsun atau ekuatorial.

Pola curah hujan tahunan di suatu stasiun (rezim hujan) ditentukan oleh kombinasi faktor meteorologis skala besar dan lokal, antara lain sirkulasi monsun, posisi dan pergeseran ITCZ, fenomena laut–atmosfer skala besar seperti ENSO dan IOD, serta osilasi intramusiman seperti MJO (Mulsandi et al., 2023). Faktor lokal seperti topografi dan kedekatan dengan laut mengubah respon lokal terhadap sinyal-sinyal tersebut, sehingga tiap stasiun dapat memiliki karakter pola hujan tahunan yang berbeda meskipun berada pada zona iklim yang sama.

Dalam penelitian ini, curah hujan harian dipandang sebagai deret waktu klimatologis di satu stasiun. Struktur datanya dapat diringkas sebagai berikut:

- Data harian: setiap baris mewakili satu tanggal (t) dengan nilai curah hujan harian $R(t)$ dalam mm.
- Representasi dasarian: data harian digabung menjadi 36 dasarian per tahun ($3 \text{ dasarian} \times 12 \text{ bulan}$) sehingga satu tahun direpresentasikan sebagai

vektor $\mathbf{x}_{\text{tahun}} = [R_{D1}, R_{D2}, \dots, R_{D36}]$. Pendekatan agregasi ke skala 10 harian lazim digunakan dalam klimatologi operasional untuk memetakan pola musiman dan pergeseran musim hujan (BMKG, n.d.).

- Rangkaian jendela harian: data harian juga diturunkan menjadi akumulasi beberapa hari terakhir (R1, R3, R5, R7, R10) untuk menangkap dinamika curah hujan jangka pendek yang relevan dengan kejadian hujan lebat dan ekstrem. Pendekatan jendela semacam ini sering digunakan dalam pemodelan hidrologi dan hujan-runoff (Wilks, 2011).

Dengan demikian, data curah hujan harian di Stasiun Meteorologi Maritim Serang dimanfaatkan untuk dua kebutuhan: (1) merangkum pola tahunan menjadi tipologi rezim hujan yang mudah dipahami, dan (2) menangkap dinamika hujan jangka pendek sebagai dasar deteksi hujan lebat harian.

2.2.2 Clustering

Clustering adalah salah satu teknik *unsupervised learning* yang bertujuan mengelompokkan sekumpulan objek tanpa label ke dalam beberapa kelompok (cluster) sehingga objek dalam satu cluster relatif mirip, sedangkan objek antarkluster relatif berbeda. Teknik ini berguna untuk menemukan struktur atau pola tersembunyi pada data tanpa informasi target (Wilks, 2011).

a. Prinsip *Unsupervised Learning* dalam Clustering

Berbeda dengan *supervised learning* yang membutuhkan label, clustering hanya memanfaatkan fitur input. Algoritma berusaha menemukan partisi data ke dalam cluster-cluster yang memaksimalkan kemiripan intrakluster dan meminimalkan perbedaan antarkluster, berdasarkan ukuran jarak atau kesamaan tertentu (misalnya jarak Euclidean atau kosinus).

b. Jenis Metode Clustering

1. K-Means Clustering

- Mengasumsikan jumlah cluster K telah ditentukan.
- Bekerja dengan meminimalkan jumlah kuadrat jarak setiap titik ke centroid cluster-nya.
- Banyak digunakan karena algoritmanya sederhana dan komputasinya efisien (Wilks, 2011).

2. Hierarchical Clustering

- Menyusun struktur hierarki cluster dalam bentuk *dendrogram* dengan pendekatan *agglomerative* (penggabungan bottom-up) atau *divisive* (pemecahan top-down).
- Tidak memerlukan penentuan K di awal, karena jumlah cluster dapat dipilih dengan memotong dendrogram pada level tertentu (Wilks, 2011).

3. DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

- Mengelompokkan titik berdasarkan kepadatan lokal dan mampu mengidentifikasi *noise*.
- Cocok untuk data dengan bentuk cluster tidak sferis.

4. Gaussian Mixture Model (GMM)

- Mengasumsikan data berasal dari campuran beberapa distribusi Gaussian, dan memberikan probabilitas keanggotaan tiap cluster (soft clustering) menggunakan algoritma EM. Dalam penelitian ini, fokus utama adalah penggunaan clustering (misalnya K-Means) pada **ruang laten Autoencoder** untuk membentuk tipologi rezim hujan tahunan.

c. Evaluasi Hasil Cluster

Beberapa indeks validasi internal yang umum digunakan adalah:

1. Silhouette Score

- Diperkenalkan oleh Rousseeuw sebagai cara grafis dan numerik untuk menilai kualitas partisi cluster (Rousseeuw, 1987).
- Menggabungkan informasi jarak rata-rata ke cluster sendiri dan ke cluster tetangga terdekat; nilai rata-rata Silhouette mendekati 1 menandakan pemisahan cluster yang baik.

2. Davies–Bouldin Index (DBI)

- Diperkenalkan oleh Davies dan Bouldin (1979) sebagai ukuran rata-rata “kemiripan terburuk” antarkluster berdasarkan rasio antara sebaran dalam cluster dan jarak antarcentroid.
- Nilai DBI yang lebih kecil menunjukkan pemisahan cluster yang lebih baik.

3. Calinski–Harabasz Index (CH Index)

- Dikenal juga sebagai *variance ratio criterion*, dikembangkan oleh Caliński dan Harabasz (1974).
- Mengukur rasio dispersi antarcluster terhadap dispersi intracluster; nilai CH yang lebih besar mengindikasikan cluster yang lebih kompak dan terpisah.

Indeks-indeks ini digunakan dalam penelitian untuk memilih konfigurasi klaster yang paling sesuai dan menilai apakah tipologi rezim hujan tahunan yang diperoleh cukup baik secara geometris sebelum diinterpretasikan secara klimatologis.

2.2.3 Deep Learning

Deep learning merupakan cabang *machine learning* yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan untuk mempelajari representasi data pada berbagai tingkat abstraksi. Pendekatan ini telah secara luas digunakan di berbagai domain, termasuk pengenalan pola, pemrosesan citra, ucapan, serta analisis data ilmiah seperti genomik dan atmosfer (LeCun et al., 2015). Dalam penelitian ini digunakan dua arsitektur utama yaitu Autoencoder (AE) dan Convolutional Neural Network (CNN).

2.2.3.1 Autoencoder

Autoencoder adalah jaringan saraf yang dilatih untuk merekonstruksi kembali input-nya sendiri, dengan struktur terdiri dari encoder dan decoder. Encoder memetakan vektor input $\mathbf{x} \in \mathbb{R}^d$ ke representasi laten berdimensi lebih rendah $\mathbf{z} \in \mathbb{R}^k$, sedangkan decoder mencoba merekonstruksi $\hat{\mathbf{x}}$ dari $\mathbf{z}$.

$$\mathbf{z} = f_{\theta}(\mathbf{x}), \hat{\mathbf{x}} = g_{\phi}(\mathbf{z})$$

Pelatihan dilakukan dengan meminimalkan *loss* rekonstruksi, misalnya MSE. Hinton dan Salakhutdinov menunjukkan bahwa *deep autoencoder* yang diinisialisasi dengan baik mampu menghasilkan kode berdimensi rendah yang lebih informatif dibanding PCA untuk berbagai jenis data berdimensi tinggi (Hinton et al., 2006).

Dalam penelitian ini, AE digunakan sebagai ekstraktor fitur tak terawasi untuk mempelajari representasi laten dari vektor 36-dasarian per tahun. Representasi laten tersebut kemudian menjadi dasar penerapan algoritma clustering untuk membentuk tipologi rezim hujan tahunan.

2.2.3.2 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) menggunakan operasi konvolusi untuk mengekstraksi fitur lokal dari data. Walaupun banyak dikenal pada pengolahan citra (2D), CNN juga dapat diterapkan pada deret waktu satu dimensi (CNN 1D) dengan menggeser kernel konvolusi sepanjang sumbu waktu (LeCun et al., 2015).

Pada CNN 1D, kernel konvolusi berukuran kecil digeser melintasi deret input sehingga menghasilkan peta fitur yang merepresentasikan pola lokal (misalnya lonjakan curah hujan dalam beberapa hari terakhir). Studi-studi terkini menunjukkan bahwa CNN 1D efektif untuk pemodelan deret waktu meteorologi dan presipitasi, misalnya untuk prakiraan curah hujan dan klasifikasi kejadian hujan ekstrem (Wilks, 2011).

Dalam penelitian ini, CNN 1D digunakan untuk membangun model deteksi/indikasi dini hujan lebat harian berdasarkan rangkaian fitur R1, R3, R5, R7, dan R10 yang dirangkai sebagai input deret waktu.

2.2.4 Perpaduan Autoencoder dan CNN

Perpaduan model dalam konteks penelitian ini merujuk pada pemanfaatan Autoencoder dan CNN dalam satu kerangka analitis yang saling melengkapi, meskipun keduanya bekerja pada blok tujuan yang berbeda. Pendekatan paduan yang menggabungkan *representation learning* tak terawasi (misalnya AE) dan

supervised learning (misalnya CNN) telah banyak digunakan untuk meningkatkan kinerja dan interpretabilitas model pada data kompleks (LeCun et al., 2015).

Secara umum, kombinasi AE–CNN dapat dilakukan dengan:

1. Melatih AE untuk mengekstraksi representasi laten, lalu menggunakan representasi ini sebagai input model klasifikasi (misalnya CNN atau jaringan lain); atau
2. Menggunakan AE dan CNN dalam dua blok analisis yang berbeda namun saling mendukung: AE untuk merumuskan struktur atau rezim iklim, dan CNN untuk memprediksi atau mendeteksi kejadian ekstrem yang terkait.


Penelitian ini mengadopsi pendekatan kedua:

- Blok A (AE + clustering): Autoencoder digunakan untuk mereduksi dimensi pola hujan tahunan (36-dasarian) dan menghasilkan representasi laten yang kemudian dikluster menjadi tipologi rezim hujan tahunan.
- Blok B (CNN 1D): CNN 1D digunakan untuk mendeteksi kejadian hujan lebat harian berdasarkan rangkaian fitur akumulasi curah hujan beberapa hari terakhir.

Dengan demikian, seluruh kerangka analisis dapat dipandang sebagai model hybrid deep learning yang memadukan AE (untuk tipologi rezim tahunan) dan CNN 1D (untuk sinyal harian), yang bersama-sama memberikan gambaran dari skala tahunan hingga harian tentang perilaku curah hujan di stasiun.

2.3 Kerangka Pemikiran

Kerangka pemikiran untuk penelitian ini kami sajikan pada Gambar 2.1 berikut.



Gambar 2. 1 Kerangka pemikiran penelitian.

Gambar 2.1 menyajikan kerangka pemikiran dengan uraian sebagai berikut. Kerangka pemikiran penelitian ini berangkat dari fenomena bahwa curah hujan di wilayah maritim seperti Serang memiliki pola yang kompleks, dipengaruhi oleh interaksi monsun, ITCZ, fenomena laut-atmosfer (seperti ENSO dan IOD), serta faktor lokal seperti topografi dan kedekatan dengan laut. Kompleksitas ini membuat pola musim hujan-kemarau di tingkat stasiun tidak selalu mudah dibaca hanya dari tabel atau grafik curah hujan bulanan. Di sisi lain, Stasiun Meteorologi Maritim Kelas I Serang menyimpan deret waktu curah hujan harian yang panjang, tetapi belum tersedia ringkasan pola tahunan dan sinyal harian yang operasional untuk mendukung perencanaan infrastruktur dan kesiapsiagaan cuaca di kawasan pesisir.

Kondisi tersebut menjadi permasalahan utama: data historis yang kaya belum diolah menjadi informasi pola hujan yang ringkas dan mudah digunakan pemangku kepentingan.

Permasalahan ini menimbulkan kebutuhan untuk melakukan analisis pola curah hujan secara lebih sistematis melalui pengelompokan pola (clustering) sehingga dapat dibentuk tipologi rezim hujan tahunan di stasiun. Dengan merepresentasikan deret harian menjadi vektor 36-dasarian per tahun, tiap tahun pengamatan dapat diperlakukan sebagai satu objek yang akan dikelompokkan ke dalam beberapa pola tahunan yang relatif homogen. Pengelompokan ini diharapkan menghasilkan gambaran yang lebih eksplisit tentang tipe pola hujan di Serang (misalnya lebih mirip monsunial, ekuatorial, atau lokal), dinamika pergeserannya antar tahun, serta implikasinya terhadap musim tanam dan potensi kejadian hujan lebat. Selain pola tahunan, deret harian juga perlu dianalisis dalam bentuk jendela waktu pendek (R1, R3, R5, R7, R10) untuk mendeteksi kondisi yang mengarah pada hujan lebat, sehingga dibutuhkan model yang mampu mengenali pola deret waktu tersebut.

Dalam konteks itulah deep learning dipandang cocok untuk analisis pola curah hujan. Pendekatan ini memungkinkan pembelajaran representasi secara otomatis dari data berdimensi tinggi dan kompleks, tanpa harus merancang seluruh fitur secara manual. Autoencoder dapat mempelajari representasi laten (kode) dari pola hujan tahunan 36-dasarian, sedangkan Convolutional Neural Network (CNN) 1D mampu mengekstraksi pola lokal dari rangkaian akumulasi hujan harian (R1/R3/R5/R7/R10) yang berhubungan dengan kejadian hujan lebat. Dengan demikian, deep learning ditempatkan sebagai jembatan antara deret waktu curah hujan yang mentah dan informasi pola yang lebih mudah diinterpretasikan, baik di skala tahunan maupun harian.

Peran Autoencoder dalam kerangka ini adalah melakukan representasi, ekstraksi fitur, dan reduksi dimensi terhadap pola hujan tahunan. Vektor 36-dasarian tiap tahun dimasukkan ke dalam Autoencoder untuk dipelajari representasi latennya yang berdimensi lebih rendah, namun tetap memuat informasi pola utama. Ruang laten inilah yang kemudian menjadi dasar penerapan algoritma clustering (misalnya K-Means) untuk membentuk beberapa kelompok rezim hujan tahunan.

Sementara itu, peran CNN adalah mendeteksi kejadian hujan lebat harian. Deret waktu hujan harian diolah menjadi fitur jendela (R1, R3, R5, R7, R10) dan diberi label hujan lebat/tidak berdasarkan ambang persentil musiman (P95–P99). CNN 1D kemudian dilatih untuk mengenali pola jangka pendek yang membedakan hari-hari dengan hujan lebat dari hari-hari biasa, sehingga menghasilkan sinyal deteksi/indikasi dini di tingkat stasiun.

Tahap berikutnya adalah integrasi Autoencoder dan CNN dalam satu kerangka analitis. Di satu sisi, blok Autoencoder + clustering menghasilkan tipologi rezim hujan tahunan yang stabil dan dapat diinterpretasikan untuk menjelaskan variasi pola hujan antar tahun di Stasiun Meteorologi Maritim Serang. Di sisi lain, blok CNN 1D menghasilkan model deteksi hujan lebat harian yang dievaluasi dengan metrik POD, FAR, CSI, dan AUROC sehingga layak dipertimbangkan sebagai prototipe sinyal operasional. Integrasi kedua blok ini menghasilkan ****output penelitian**** berupa: (1) tipologi rezim hujan tahunan beserta tren kemunculannya yang dapat digunakan dalam komunikasi musim dan pengelolaan sumber daya air, dan (2) prototipe sinyal deteksi/indikasi dini hujan lebat harian yang sederhana dan siap dioperasikan di level stasiun. Selain memberikan manfaat praktis bagi stasiun, kerangka ini juga berkontribusi pada pengembangan aplikasi deep learning di bidang Teknik Informatika untuk analisis deret waktu curah hujan.

