

**ANALISIS MODEL PREDIKSI PROBABILISTIK HUJAN LEBAT
HARIAN MENGGUNAKAN AUTOENCODER DAN CNN PADA
DI STASIUN METEOROLOGI MARITIM SERANG**

PROPOSAL TESIS



**Oleh:
DIAN HERDIANINGSIH
241012000020**

**PROGRAM STUDI TEKNIK INFORMATIKA S-2
PROGRAM PASCASARJANA
UNIVERSITAS PAMULANG
TANGERANG SELATAN
2025**

**ANALISIS MODEL PREDIKSI PROBABILISTIK HUJAN LEBAT
HARIAN MENGGUNAKAN AUTOENCODER DAN CNN PADA
DI STASIUN METEOROLOGI MARITIM SERANG**

PROPOSAL TESIS

**Diajukan Untuk Memenuhi Gelar Magister Komputer Pada Program
Pasca Sarjana Universitas Pamulang**



**Oleh:
DIAN HERDIANINGSIH
241012000020**

**PROGRAM STUDI TEKNIK INFORMATIKA S-2
PROGRAM PASCASARJANA
UNIVERSITAS PAMULANG
TANGERANG SELATAN
2025**

LEMBAR PERSETUJUAN PROPOSAL TESIS

ANALISIS MODEL PREDIKSI PROBABILISTIK HUJAN LEBAT HARIAN MENGGUNAKAN AUTOENCODER DAN CNN PADA DI STASIUN METEOROLOGI MARITIM SERANG

Telah disetujui untuk disidangkan pada Program Studi Teknik Informatika S-2
Universitas Pamulang
Pada tanggal

Oleh:
Dian Herdianingsih
241012000020

Mengetahui :
Kaprodi Teknik Informatika S-2

Dr. Sajarwo Anggai., S.ST., M.T.
NIDN : 0421108703

LEMBAR PERNYATAAN TESIS

Dengan ini saya menyatakan bahwa dalam tesis ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah tesis ini dan disebutkan dalam daftar pustaka.

Tangerang Selatan,20....

Dian Herdianingsih

241012000020

KATA PENGANTAR

Puji syukur penulis ucapkan kepada Allah *subhanahu wa ta'ala*, karena atas kuasa dan rahmat-Nya penulis dapat menyelesaikan proposal tesis ini. Penulisan tesis ini dilakukan dalam rangka memenuhi salah satu syarat untuk disetujui sebagai Tesis pada Program Studi Teknik Informatika UNPAM. Penulis menyadari bahwa tanpa bantuan dan bimbingan dari berbagai pihak, penulisan proposal ini tidak dapat terlaksana dengan baik. Oleh karena itu Penulis mengucapkan terimakasih kepada:

1. Bapak Dr. Pranoto, S.E., M.M selaku ketua Yayasan Sasmita Jaya.
2. Bapak Dr. E. Nurzaman, AM., M.M., M.Si selaku Rektor Universitas Pamulang.
3. Sahrul Anwar, S.E., S.Pd., M.Pd. selaku Direktur Pascasarjana Universitas Pamulang.
4. Dr. Sajarwo Anggai., S.ST., M.T. sebagai Ketua Program Studi Teknik Informatika S-2 Universitas Pamulang.
5. Para Bapak Ibu Dosen Pengampu di kelas dan Pembimbing Tesis
6. Suami , anak-anak , saudara kerabat , pimpinan dan teman-teman sekantor Di BMKG Serang dan teman-teman 1 angkatan kelas 003 BMKG Prodi Teknik Informatika

Saya menyadari mungkin proposal tesis ini masih memiliki keterbatasan ,oleh karena itu, kritik dan saran yang konstruktif sangat diharapkan guna penyempurnaan penelitian di masa mendatang. Besar harapan bahwa hasil penelitian ini dapat memberikan kontribusi akademik, implikasi praktis, serta membuka peluang penelitian lanjutan dalam bidang Teknik Informatika Akhir kata, saya berharap Allah *subhanahu wa ta'ala* berkenan membalas segala kebaikan semua pihak yang telah membantu.

Penulis,

Dian Herdianingsih

ABSTRAK

Perencanaan infrastruktur dan kesiapsiagaan cuaca di wilayah pesisir membutuhkan informasi pola curah hujan yang ringkas dan mudah dipahami, namun hingga kini produk klimatologis semacam itu belum tersedia di Stasiun Meteorologi Maritim Kelas I Serang. Ketidadaan ringkasan pola tahunan serta sinyal harian yang operasional menghambat pemanfaatan data historis yang sebenarnya sangat kaya untuk mendukung layanan publik. Penelitian ini bertujuan membentuk tipologi pola curah hujan tahunan berbasis Autoencoder (AE) serta merancang sinyal deteksi/indikasi dini hujan harian menggunakan Convolutional Neural Network (CNN) 1D pada tingkat stasiun.

Data utama penelitian berupa curah hujan harian periode 1995–2024 yang diperoleh dari Stasiun Meteorologi Maritim Serang, kemudian dikonsolidasikan menjadi rangkaian dasarian dan jendela harian sebagai dasar analisis. Pengumpulan data dilakukan melalui proses ekstraksi, verifikasi kelengkapan, serta penyusunan ulang menjadi 36-dasarian untuk analisis tahunan dan rangkaian R1/R3/R5/R7/R10 untuk analisis harian. Analisis data meliputi pembangunan representasi tahunan menggunakan AE untuk mereduksi pola 36-dasarian serta pemodelan CNN 1D untuk deteksi hujan harian dengan definisi ekstrem berbasis persentil musiman P95–P99. Evaluasi model dilakukan menggunakan Silhouette, Davies–Bouldin, dan Adjusted Rand Index berbasis bootstrap untuk menilai kualitas–stabilitas kluster, serta metrik POD, FAR, CSI, dan AUROC untuk menilai kinerja model CNN 1D. Penelitian ini menghasilkan tipologi rezim tahunan yang stabil dan dapat diinterpretasikan, ringkasan tren kemunculannya untuk mendukung komunikasi musim, serta prototipe deteksi hujan harian yang sederhana dan siap dioperasikan pada level stasiun.

Index : Autoencoder; CNN 1D; Regim curah hujan; Dasarian; Peringatan dini hujan lebat.

ABSTRACT

Infrastructure planning and weather preparedness in coastal areas require concise and easy-to-understand information on rainfall patterns, yet such climatological products are currently unavailable at Serang Maritime Meteorological Station. The absence of an operational summary of annual patterns and daily signals hinders the use of rich historical data to support public services. This study aims to construct a typology of annual rainfall patterns using an Autoencoder (AE) and to design a station-level daily rainfall detection/early-indication signal using a one-dimensional Convolutional Neural Network (1D CNN).

The main data used in this research are daily rainfall records for the period 1995–2024 obtained from Serang Maritime Meteorological Station, which are then consolidated into decadal series and daily windows as the basis for analysis. Data collection is carried out through extraction, completeness verification, and restructuring into 36 decadals for annual analysis and R1/R3/R5/R7/R10 sequences for daily analysis. The data analysis includes building an annual representation using an AE to reduce the 36-decadal pattern and modelling a 1D CNN for daily rainfall detection, with extreme events defined using seasonal percentiles P95–P99. Model evaluation is performed using the Silhouette, Davies–Bouldin, and bootstrap-based Adjusted Rand Index to assess cluster quality and stability, as well as POD, FAR, CSI, and AUROC metrics to assess the performance of the 1D CNN model. This study produces an interpretable and stable typology of annual rainfall regimes, a summary of their occurrence trends to support seasonal communication, and a simple prototype for daily rainfall detection that is ready to be operated at the station level.

Index : Autoencoder; CNN 1D; Rainfall regimes; Ten-day Rainfall; Early Warning.

DAFTAR ISI

LEMBAR PERSETUJUAN PROPOSAL TESIS	i
LEMBAR PERNYATAAN TESIS.....	ii
KATA PENGANTAR.....	iii
ABSTRAK	iv
ABSTRACT.....	v
DAFTAR ISI.....	vi
DAFTAR TABEL	viii
DAFTAR GAMBAR.....	ix
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Permasalahan Penelitian	3
1.2.1 Identifikasi Masalah	3
1.2.2 Ruang Lingkup Masalah.....	6
1.3 Rumusan Masalah.....	6
1.4 Tujuan dan Manfaat Penelitian	7
1.4.1 Tujuan Penelitian.....	7
1.4.2 Manfaat Penelitian.....	7
1.5 Sistematika Penulisan	8
BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN.....	10
2.1 Tinjauan Pustaka.....	10
2.1.1 Studi tentang pola dan rezim hujan	10
2.1.2 Pengelompokan dan regionalisasi curah hujan berbasis klastering	11
2.1.3 Autoencoder untuk data iklim dan deret waktu.....	12
2.1.4 Deep learning berbasis CNN 1D untuk prediksi curah hujan dan kejadian ekstrem.....	13
2.1.5 Sintesis dan posisi penelitian.....	15
2.2 Landasan Teori	24
2.2.1 Deep Learning	27
2.2.2 Perpaduan Autoencoder dan Convolutional Neural Network	28

2.3	Kerangka Pemikiran	29
BAB III	METODOLOGI PENELITIAN	34
3.1	Analisis Kebutuhan.....	34
3.1.1	Dataset dan sumber data.....	35
3.1.2	Atribut, Fitur, dan Label.....	35
3.1.3	Populasi, Sampel, dan Teknik Sampling.....	37
3.1.4	Metode pengumpulan dan pra-pemrosesan data	38
3.2	Perancangan Penelitian.....	38
3.2.1	Rancangan teknis tipologi rejim hujan tahunan	42
3.2.2	Rancangan Teknis Sinyal Deteksi/Indikasi Dini Hujan Lebat	44
3.2.3	Analisis dan evaluasi model	45
3.3	Jadwal Penelitian	47
	DAFTAR PUSTAKA.....	49

DAFTAR TABEL

Tabel 1.1 Daftar permohonan layanan terkait klimatologi curah hujan di Stasiun Meteorologi Maritim Serang.....	4
Tabel 2.1 Kajian penelitian terdahulu.	16
Tabel 3. 1 Rencana jadwal penelitian.	47

DAFTAR GAMBAR

Gambar 2.1 Kerangka pemikiran penelitian.	30
Gambar 3.1 Alur penelitian.....	39

BAB I

PENDAHULUAN

1.1 Latar Belakang

Cuaca dan iklim berpengaruh langsung pada berbagai sektor strategis, mulai dari pengelolaan sumber daya air hingga perencanaan infrastruktur publik (BMKG, 2022; Mahmoud et al., 2014). Pola dan variabilitas curah hujan menentukan kinerja sistem drainase, pengelolaan tampungan air, serta risiko banjir dan kekeringan yang berdampak pada ekonomi dan keselamatan masyarakat. Oleh karena itu, kemampuan untuk mengenali perilaku siklus curah hujan pada skala lokal menjadi kebutuhan operasional bagi pemerintah daerah dan pemangku kepentingan lain, sejalan dengan mandat penyediaan informasi iklim pada dokumen kebijakan dan pedoman kelembagaan yang dirujuk oleh Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) dan World Meteorological Organization (WMO) (Steward, 2011).

Klimatologi Indonesia bersifat kompleks karena pengaruh posisi ekuator, geografis kepulauan, dan dinamika samudra-atmosfer (Hermawan et al., 2025). Serang termasuk wilayah dengan pola hujan monsunial, dengan curah hujan umumnya tinggi pada Desember hingga Maret dan relatif rendah pada Juni hingga Oktober (BMKG, 2022). Variabilitas antar-tahun tetap besar, terutama dipengaruhi oleh fenomena berskala besar seperti El Niño-Southern Oscillation (ENSO) dan Madden-Julian Oscillation (MJO) (Winarto et al., 2017). Informasi klimatologis ini menjadi tantangan bagi penyedia layanan klimatologis seperti BMKG, khususnya pada Stasiun Meteorologi Maritim Kelas I Serang.

Dari sisi layanan publik, BMKG memiliki tugas menyediakan informasi cuaca dan iklim kepada pengguna, termasuk pemerintah daerah, dan pada wilayah Kota Serang tugas teknis tersebut dijalankan oleh Stasiun Meteorologi Serang. Ketersediaan produk informasi pola curah hujan lokal yang ringkas, dapat ditelusuri, dan mudah dipahami akan membantu sinkronisasi kegiatan kesiapsiagaan, pemeliharaan infrastruktur, dan komunikasi risiko di tingkat daerah.

Berangkat dari kebutuhan tersebut, penelitian ini memfokuskan pemaknaan pola musiman tahunan dan sinyal dini kejadian hujan harian berbasis data stasiun

tunggal. Pendekatan yang digunakan adalah Autoencoder untuk mempelajari representasi terkompresi dari sidik jari tahunan berbasis dasarian sehingga regime curah hujan dapat diidentifikasi secara tak terawasi, serta Convolutional Neural Network satu dimensi untuk mengolah jendela deret waktu harian dan menghasilkan deteksi atau indikasi dini hujan lebat berbasis ambang persentil musiman. Pemilihan ini menjaga kesesuaian dengan ketersediaan data lokal dan menghasilkan keluaran yang relevan bagi pemangku kepentingan, sekaligus selaras dengan kebutuhan operasional.

Dari sudut pandang Teknik Informatika, kebutuhan produk klimatologis lokal tersebut menuntut pengembangan model komputasional yang mampu mengekstraksi pola dari deret waktu curah hujan secara otomatis dan terukur. Autoencoder (AE) menawarkan cara untuk mempelajari representasi terkompresi dari pola tahunan berbasis dasarian, sedangkan Convolutional Neural Network satu dimensi (CNN 1D) telah banyak digunakan untuk ekstraksi fitur pada deret waktu. Penelitian ini memanfaatkan kedua arsitektur tersebut untuk membangun pipeline analitik yang tidak hanya menghasilkan tipologi rezim hujan yang stabil, tetapi juga sinyal deteksi dini hujan lebat yang dapat dioperasikan pada tingkat stasiun. Dengan demikian, penelitian ini berkontribusi pada pengembangan penerapan *deep learning* dalam pengolahan data iklim lokal sekaligus menjawab kebutuhan layanan klimatologis di Stasiun Meteorologi Maritim Serang.

Penelitian mengenai analisis dan prediksi curah hujan telah banyak dilakukan dengan berbagai pendekatan statistik maupun machine learning. Namun, sebagian besar penelitian sebelumnya berfokus pada pemodelan prediksi curah hujan secara langsung tanpa terlebih dahulu mengeksplorasi pola distribusi curah hujan historis yang dapat memberikan pemahaman lebih mendalam terhadap karakteristik rezim hujan pada suatu wilayah. Selain itu, beberapa penelitian menggunakan metode deep learning secara terpisah tanpa mengintegrasikan analisis pola data dengan model prediksi.

Oleh karena itu, penelitian ini menawarkan pendekatan yang berbeda dengan mengintegrasikan analisis representasi pola curah hujan menggunakan Autoencoder dan pemodelan prediksi kejadian hujan lebat menggunakan Convolutional Neural Network (CNN) satu dimensi. Pendekatan ini

memungkinkan proses analisis dilakukan secara bertahap, dimulai dari pemahaman struktur pola curah hujan historis hingga pembangunan model prediksi kejadian hujan lebat berdasarkan pola temporal data.

Secara lebih spesifik, kebaruan dalam penelitian ini dapat dirumuskan sebagai berikut:

a. Pendekatan pembelajaran representasi pola curah hujan

Penelitian ini menggunakan Autoencoder untuk mempelajari representasi laten dari data curah hujan historis sehingga pola distribusi curah hujan tahunan dapat direpresentasikan dalam bentuk fitur yang lebih ringkas dan informatif.

b. Integrasi analisis pola hujan dengan model prediksi berbasis deep learning

Berbeda dengan penelitian sebelumnya yang langsung melakukan prediksi, penelitian ini mengombinasikan analisis pola curah hujan menggunakan Autoencoder dengan model prediksi hujan lebat menggunakan CNN satu dimensi.

c. Pemanfaatan pola temporal akumulasi curah hujan sebagai fitur prediksi

Model prediksi dibangun dengan memanfaatkan akumulasi curah hujan beberapa hari sebelumnya (R1, R3, R5, R7, R10) sebagai representasi pola temporal untuk mendeteksi probabilitas kejadian hujan lebat pada tingkat stasiun meteorologi.

Dengan pendekatan tersebut, penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan metode analisis pola curah hujan serta model prediksi kejadian hujan lebat berbasis deep learning yang lebih informatif dan adaptif terhadap karakteristik data meteorologi lokal

1.2 Permasalahan Penelitian

1.2.1 Identifikasi Masalah

Pada level layanan, Stasiun Meteorologi Maritim Serang belum memiliki produk informasi klimatologis yang secara khusus merangkum pola atau *regime* curah hujan lokal untuk Kota Serang. Kekosongan produk ini mengakibatkan belum tersedianya ringkasan pola tahunan yang konsisten sebagai rujukan operasional bagi pemangku kepentingan daerah (perencanaan, kesiapsiagaan, dan komunikasi

risiko). Padahal, BMKG memandatkan penyediaan informasi cuaca dan iklim bagi pengguna, termasuk pemerintah daerah, dan pelaksanaan teknisnya di wilayah Serang berada pada stasiun setempat (BMKG, 2016, 2020b). Dengan kondisi tersebut, kebutuhan akan produk pola/rezim hujan lokal menjadi mendesak sebagai bagian dari pelayanan informasi iklim di tingkat stasiun.

Secara teknis, layanan yang diberikan masih didasarkan pada analisis konvensional dan belum didukung oleh model komputasional yang terdokumentasi dengan baik untuk mengenali rezim hujan tahunan dan memberikan sinyal dini kejadian hujan lebat.

Di sisi permintaan, daftar kebutuhan informasi dari pemangku kepentingan Stasiun Meteorologi Maritim Serang sebagaimana disajikan pada Tabel 1.1 menunjukkan bahwa pengguna meminta beragam keluaran terkait curah hujan yang dapat dipakai untuk perencanaan dan kesiapsiagaan. Daftar tersebut memperkuat bukti adanya kesenjangan antara kebutuhan informasi dan ketersediaan produk klimatologi lokal pada level stasiun. Dengan demikian, masalah inti penelitian ini dirumuskan sebagai ketiadaan produk klimatologi berbasis rezim curah hujan yang ringkas, dapat ditelusuri, dan mudah dioperasikan untuk mendukung pengambilan keputusan di wilayah Serang.

Tabel 1.1 Daftar permohonan layanan terkait klimatologi curah hujan di Stasiun Meteorologi Maritim Serang

(Sumber: Stasiun Meteorologi Maritim Serang)

No	Tanggal	Pemohon	Layanan yang Dimohonkan
1	07-Mar-22	BPBD Kab Serang	Prediksi Curah Hujan 3 Bulan Ke depan
2	08-Jun-22	Krakatau Bandar Samudra	Informasi CH dan Prediksi CH 3 Bulan Kedepan
3	06-Feb-23	Dinas Pertanian Kab Serang	Prakiraan Musim dan Prediksi CH
4	15-Dec-23	Dinas Ketahanan Pangan Kab Serang	Informasi Curah Hujan dan Normal CH

No	Tanggal	Pemohon	Layanan yang Dimohonkan
5	15-Feb-24	PT Evintek Indonesia	Informasi Curah Hujan
6	06-Oct-24	Dinas Lingkungan hidup Kab Serang	Data Ch dan Prediksi Ch 3 bulan kedepan
7	04-Apr-25	Dinas Lingkungan hidup Kab Serang	Data Ch dan Prediksi Ch 3 bulan kedepan
8	07-Apr-25	BPBD Kab Serang	Prakiraan Musim dan Prediksi CH
9	08-Sep-25	Dinas Ketahanan Pangan	Data dan Prakirraan Cuaca ekstrem untuk keperluan mitigasi Nelayan Tradisional
10	03-Oct-25	PT. Waskita Karya	Informasi CH dan Prediksi CH Kota Serang

Sebagai konsekuensi, diperlukan pendekatan komputasional yang memanfaatkan data stasiun tunggal untuk: (i) mengekstraksi dan menamai rezim curah hujan tahunan secara konsisten, dan (ii) menurunkan sinyal operasional yang relevan bagi pengguna. Arah ini sejalan dengan mandat layanan informasi iklim dan kebutuhan pemangku kepentingan yang telah diidentifikasi pada dokumen internal serta daftar permintaan informasi.

Penelitian mengenai analisis dan prediksi curah hujan telah banyak dilakukan menggunakan berbagai metode statistik maupun machine learning. Namun, sebagian besar penelitian berfokus pada pemodelan prediksi secara langsung tanpa terlebih dahulu mengeksplorasi pola distribusi curah hujan historis. Selain itu, penggunaan metode deep learning sering dilakukan secara terpisah tanpa mengintegrasikan analisis pola data dengan model prediksi.

Penelitian ini menawarkan pendekatan yang mengintegrasikan Autoencoder dan Convolutional Neural Network (CNN) satu dimensi dalam satu kerangka analisis. Autoencoder digunakan untuk mempelajari representasi pola curah hujan historis sehingga dapat diidentifikasi tipologi pola hujan tahunan. Selanjutnya, CNN digunakan untuk membangun model prediksi probabilistik kejadian hujan lebat berdasarkan pola temporal curah hujan beberapa hari sebelumnya.

Secara umum, kebaruan penelitian ini terletak pada integrasi analisis pola curah hujan menggunakan Autoencoder dengan model prediksi hujan lebat menggunakan CNN, serta pemanfaatan akumulasi curah hujan beberapa hari sebelumnya sebagai fitur temporal dalam model prediksi pada tingkat stasiun meteorologi

1.2.2 Ruang Lingkup Masalah

Berdasarkan beberapa pokok permasalahan yang telah diuraikan pada identifikasi masalah di atas, maka penelitian dibatasi pada poin-poin berikut.

- a. Penelitian dibatasi pada Stasiun Meteorologi Maritim Serang sebagai sumber data tunggal. Temuan bersifat representasi lokal stasiun dan tidak digeneralisasi secara spasial ke wilayah yang lebih luas.
- b. Data utama adalah curah hujan harian dengan rentang kerja 1995–2024 (± 30 tahun). Derivasi resolusi waktu yang digunakan adalah sebagai berikut.
 - i. Dasarian (36 slot per tahun) untuk pembentukan rezim tahunan.
 - ii. Jendela harian bergulir untuk sinyal alert (R1, R3, R5, R7, R10).
- c. Keluaran yang dituju.
 - i. Produk klimatologis berupa tipologi curah hujan tahunan pada tingkat stasiun, disertai ilustrasi profil musiman dan ringkasan kemunculannya per periode.
 - ii. Sinyal operasional berupa deteksi dini kejadian hujan harian kategori lebat berdasarkan ambang persentil musiman.

1.3 Rumusan Masalah

Berdasarkan identifikasi masalah di atas maka dapat dirumuskan masalah yaitu sebagai berikut.

- a. Bagaimana pola distribusi curah hujan tahunan pada Stasiun Meteorologi Maritim Serang jika direpresentasikan dalam bentuk data dasarian? Bagaimana pola distribusi curah hujan tahunan pada Stasiun

Meteorologi Maritim Serang jika direpresentasikan dalam bentuk data dasarian?

- b. Bagaimana metode pembelajaran representasi menggunakan Autoencoder dapat digunakan untuk mengidentifikasi tipologi pola curah hujan tahunan yang memiliki karakteristik serupa?
- c. Bagaimana pola temporal curah hujan harian dapat dimanfaatkan untuk membangun serta mengevaluasi model prediksi probabilistik kejadian hujan lebat menggunakan CNN 1D?

1.4 Tujuan dan Manfaat Penelitian

1.4.1 Tujuan Penelitian

Berdasarkan perumusan masalah, tujuan penelitian ini adalah sebagai berikut.

- a. Menganalisis pola distribusi curah hujan tahunan pada Stasiun Meteorologi Maritim Serang berdasarkan data historis curah hujan.
- b. Mengidentifikasi tipologi pola curah hujan tahunan menggunakan metode pembelajaran representasi berbasis Autoencoder untuk mengelompokkan pola hujan yang memiliki karakteristik serupa.
- c. Mengembangkan model prediksi probabilistik kejadian hujan lebat harian menggunakan metode Convolutional Neural Network (CNN) 1 Dimensi berdasarkan pola temporal curah hujan beberapa hari sebelumnya.

1.4.2 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan beberapa manfaat sebagai berikut:

- a. Manfaat Ilmiah

Penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan kajian klimatologi dan pemodelan curah hujan, khususnya dalam memahami pola distribusi curah hujan tahunan serta karakteristik rezim hujan pada

tingkat stasiun meteorologi melalui pendekatan analisis data berbasis pembelajaran mendalam.

b. Manfaat Metodologis

Penelitian ini memberikan kontribusi dalam penerapan metode deep learning, khususnya Autoencoder untuk pembelajaran representasi pola curah hujan dan Convolutional Neural Network (CNN) satu dimensi untuk pemodelan prediksi probabilistik kejadian hujan lebat, sehingga dapat menjadi referensi metodologi bagi penelitian serupa di bidang meteorologi dan sains data.

c. Manfaat Praktis

Hasil penelitian ini diharapkan dapat menjadi dasar pengembangan sistem prediksi kejadian hujan lebat berbasis data historis pada tingkat stasiun meteorologi, sehingga dapat mendukung upaya peningkatan layanan informasi cuaca serta mitigasi risiko yang berkaitan dengan kejadian hujan lebat

1.5 Sistematika Penulisan

Sistematika penulisan menjelaskan tentang berapa penjelasan singkat isi dari masing-masing bab dalam proposal tesis ini sebagai berikut.

BAB I PENDAHULUAN

Bab ini mengemukakan latar belakang masalah yang diteliti, identifikasi masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, metode penelitian dan sistematika penulisan.

BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN

Bab ini menyajikan tinjauan pustaka terhadap penelitian terdahulu yang relevan, landasan teori mengenai curah hujan dan pola musim di Indonesia, konsep rezim hujan, Autoencoder, Convolutional Neural Network (CNN) 1D, serta metrik evaluasi kluster dan model klasifikasi. Bab ini juga memuat kerangka pemikiran yang menggambarkan alur logis penelitian.

BAB III METODE PENELITIAN

Bab ini menguraikan analisis kebutuhan penelitian, termasuk deskripsi dataset dan lingkungan komputasi, rancangan penelitian dalam bentuk *flowchart*, tahapan pemrosesan data, pembentukan tipologi rezim hujan berbasis Autoencoder, penyusunan model CNN 1D untuk sinyal hujan harian, serta teknik analisis dan evaluasi model yang digunakan.

BAB II

LANDASAN TEORI DAN KERANGKA PEMIKIRAN

Bab ini menyajikan tinjauan pustaka terhadap penelitian terdahulu yang relevan, landasan teori mengenai curah hujan dan pola musim di Indonesia, konsep rezim hujan, Autoencoder, Convolutional Neural Network (CNN) 1D, serta metrik evaluasi kluster dan model klasifikasi. Bab ini juga memuat kerangka pemikiran yang menggambarkan alur logis penelitian

2.1 Tinjauan Pustaka

2.1.1 Studi tentang pola dan rezim hujan

Kajian tentang pola dan rezim curah hujan di kawasan Asia Tenggara–Maritim telah lama menunjukkan bahwa wilayah ini didominasi oleh pola monsun dengan perbedaan jelas antara rezim hujan musim panas dan musim dingin di belahan bumi utara dan selatan khatulistiwa. Chang et al. (2005) menguraikan siklus tahunan curah hujan Asia Tenggara berdasarkan kombinasi faktor sirkulasi monsun dan konveksi laut–daratan, dan menunjukkan adanya perbedaan rezim hujan boreal summer dan boreal winter yang memengaruhi distribusi curah hujan bulanan sepanjang tahun.

Di tingkat regional yang lebih sempit, penelitian terdahulu memanfaatkan indeks musim (seasonality index) untuk mengklasifikasikan rezim hujan menjadi beberapa kelas, mulai dari sangat merata hingga sangat musiman, misalnya pada kajian tentang zona iklim Borneo (Sa’adi et al., 2021). Penelitian tersebut membagi rezim curah hujan menjadi tujuh kelas berdasarkan nilai indeks musim, sehingga setiap wilayah dapat dikaitkan dengan karakteristik “sangat merata”, “musiman dengan musim kering pendek”, hingga “sangat musiman dengan satu musim hujan dominan.”

Kajian klimatologi kawasan Indonesia juga menekankan bahwa sebagian besar wilayah memiliki rezim hujan monsun dengan satu atau dua puncak hujan, dan bahwa informasi tentang pola tahunan ini penting untuk keperluan perencanaan sektor pertanian, sumber daya air, dan kebencanaan (Gunawan, 2006). Namun,

sebagian besar kajian tersebut masih berfokus pada deskripsi statistik dan pemetaan zona iklim skala luas, bukan pada pengembangan produk tipologi pola tahunan yang terdokumentasi untuk tingkat stasiun tunggal.

Dalam penelitian ini Autoencoder dan CNN 1D tidak digunakan sebagai metode yang dibandingkan, melainkan sebagai dua pendekatan yang memiliki fungsi berbeda namun saling melengkapi. Autoencoder digunakan untuk mempelajari representasi pola curah hujan historis, sedangkan CNN digunakan sebagai model prediksi kejadian hujan lebat berdasarkan pola temporal curah hujan

2.1.2 Pengelompokan dan regionalisasi curah hujan berbasis klustering

Pendekatan klustering telah banyak digunakan untuk mengidentifikasi pola curah hujan dan mengelompokkan wilayah ke dalam rezim hujan yang homogen. Ahmad Basri et al. (2021) merancang skema regionalisasi rezim hujan menggunakan kombinasi Random Forest dan Bootstrap (hybrid RF-Bs) yang dikombinasikan dengan analisis kluster hierarkis. Mereka menunjukkan bahwa analisis kluster dapat mengungkap pola perilaku rezim hujan di suatu wilayah dengan mengelompokkan titik hujan ke dalam kluster-kluster yang homogen berdasarkan karakteristik curah hujan, sekaligus menurunkan galat Root Mean Square Error (RMSE) dan Mean Absolute Error (MAE) melalui prosedur kombinasi tersebut.

Di Indonesia, penelitian Suryanto (2017) membandingkan pengelompokan curah hujan 15 harian di Provinsi Daerah Istimewa Yogyakarta menggunakan fuzzy c-means dan K-Means. Dengan menggunakan indeks validasi, penelitian ini menyimpulkan bahwa K-Means lebih sesuai untuk pengelompokan pola curah hujan 15 harian di wilayah tersebut dibanding fuzzy c-means, sekaligus mengilustrasikan pentingnya pemilihan indeks validasi yang tepat dalam menilai kualitas hasil kluster. Penelitian lain yang menganalisis curah hujan di Indonesia menggunakan pendekatan klustering deret waktu juga menunjukkan bahwa teknik kluster mampu mengungkap tren dan variabilitas curah hujan pada skala spasial yang luas, misalnya dengan mengelompokkan stasiun-stasiun hujan berdasarkan kemiripan deret waktu curah hujan tahunan (Iskandar et al., 2025).

Di luar Indonesia, berbagai pendekatan klastering deret waktu curah hujan juga dikembangkan. Texeira dkk. mengembangkan metode komputasional untuk menganalisis deret waktu presipitasi di wilayah Amazon dengan teknik pembelajaran mesin, sehingga pola hujan tahunan di ratusan stasiun dapat dikelompokkan ke dalam pola-pola tipikal yang berguna untuk analisis hidrologi dan perencanaan (Texeira, 2025). Studi lain mengevaluasi stabilitas hasil klaster curah hujan ekstrem dan menunjukkan bahwa indeks seperti Silhouette, Davies–Bouldin, dan pengukuran stabilitas berbasis resampling dapat digunakan untuk menilai keandalan struktur klaster yang diperoleh (Mariana et al., 2021).

Secara umum, kajian-kajian tersebut menegaskan bahwa: (1) klastering efektif untuk mengidentifikasi pola curah hujan; (2) pemilihan indeks validasi dan analisis stabilitas klaster sangat krusial; dan (3) sebagian besar studi berfokus pada multi-stasiun atau regional, bukan pada perancangan tipologi pola tahunan yang operasional di satu stasiun tertentu.

2.1.3 Autoencoder untuk data iklim dan deret waktu

Dalam beberapa tahun terakhir, Autoencoder (AE) dan variannya menjadi salah satu pendekatan populer untuk pembelajaran representasi (representation learning) dari deret waktu dan data iklim berdimensi tinggi. Kurihana et al. (2024) mengusulkan pendekatan klasifikasi iklim berbasis clustering autoencoder, yang memanfaatkan AE tak terawasi untuk melakukan reduksi dimensi keluaran model iklim, kemudian mengelompokkan vektor laten tersebut menjadi pola-pola iklim yang bermakna. Studi ini menunjukkan bahwa AE dapat menghasilkan representasi iklim yang lebih informatif dibandingkan teknik reduksi dimensi tradisional seperti PCA, sehingga memudahkan proses klastering pola iklim.

Pada penelitian lain, Ibebuchi (2024) memperkenalkan pendekatan pengelompokan deret waktu fuzzy menggunakan jaringan saraf autoencoder untuk mengelompokkan tipe sirkulasi atmosfer. Autoencoder digunakan untuk mentransformasikan deret waktu tekanan permukaan laut menjadi ruang laten berdimensi rendah yang lebih padat, sehingga proses klastering fuzzy terhadap pola sirkulasi atmosfer dapat dilakukan secara lebih efisien dan tahan terhadap perubahan data. Hasilnya menunjukkan bahwa transformasi nonlinier oleh AE

meningkatkan pemisahan kluster dibandingkan jika klastering langsung dilakukan di ruang asli.

Di sisi lain, beberapa penelitian mengembangkan varian Autoencoder khusus untuk data iklim dan deret waktu. Spuler et al. (2025) memperkenalkan metode variational autoencoder (VAE) untuk mengidentifikasi rezim sirkulasi probabilistik yang secara khusus ditargetkan pada pola presipitasi lokal, sehingga rezim yang dihasilkan tidak hanya prediktif tetapi juga informatif terhadap dampak di skala lokal. Nguyen & Quanz (2021) mengusulkan temporal latent auto-encoder yang mampu melakukan faktoriasi nonlinier deret waktu multivariat dan mempelajari representasi laten yang cocok untuk tugas prediksi dan analisis struktur dinamis. Penelitian lain menggunakan graph autoencoder untuk merepresentasikan variabel iklim seperti presipitasi dan suhu dalam struktur graf, sehingga hubungan spasial dan telekoneksi iklim dapat dipertahankan dalam proses pembelajaran representasi (Agarwal et al., 2024).

Secara garis besar, literatur-literatur tersebut menegaskan bahwa Autoencoder dan variannya efektif untuk: (1) melakukan reduksi dimensi data iklim atau deret waktu cuaca; (2) menyediakan vektor laten yang lebih sesuai untuk klastering; dan (3) mengaitkan rezim sirkulasi atau iklim dengan pola presipitasi. Namun, pemanfaatan AE untuk membangun tipologi rezim hujan tahunan pada skala stasiun tunggal dengan representasi berbasis dasarian masih relatif jarang dijumpai.

2.1.4 Deep learning berbasis CNN 1D untuk prediksi curah hujan dan kejadian ekstrem

Convolutional Neural Network satu dimensi (CNN 1D) banyak digunakan untuk mengekstraksi fitur lokal dari deret waktu meteorologi dan hidrologi. Beberapa penelitian secara spesifik menerapkannya pada prediksi curah hujan harian. Sebuah studi tentang prediksi curah hujan harian di Indonesia menggunakan model CNN 1D untuk memprediksi curah hujan hingga 14 hari ke depan berdasarkan data observasi BMKG, dan menunjukkan bahwa CNN 1D mampu menangkap fitur temporal yang relevan untuk prakiraan jangka pendek (Sari et al., 2020). Ponnopratt (2021) mengembangkan model deep learning yang

memanfaatkan korelasi jangka pendek dan pola musiman jangka panjang untuk prakiraan presipitasi harian, dan menemukan bahwa arsitektur berbasis CNN/LSTM dapat mengungguli beberapa model tradisional dalam hal akurasi.

Pengembangan lebih lanjut menggabungkan CNN 1D dengan arsitektur lain. Penelitian Liu et al. (2023) mengusulkan model *nowcasting* intensitas curah hujan berbasis Conv1D–Transformer (RLNformer) yang mengklasifikasikan deret waktu curah hujan ke dalam empat kategori (tidak hujan hingga hujan lebat dan di atasnya). Studi tersebut menunjukkan bahwa kombinasi ekstraksi fitur lokal oleh Conv1D dan pemodelan ketergantungan jangka panjang oleh Transformer dapat meningkatkan akurasi klasifikasi level hujan. Penelitian lain juga menggabungkan *denoising* Autoencoder dengan Convolutional LSTM untuk prediksi cuaca laut global dan menemukan bahwa penghilangan *noise* serta pembelajaran fitur spasio-temporal meningkatkan kinerja prakiraan dibandingkan metode numerik murni (Kim et al., 2020).

Dalam konteks kejadian ekstrem, beberapa penelitian memanfaatkan CNN untuk mengenali pola yang mengarah pada hujan lebat atau peristiwa ekstrem lain. Xie et al. (2023) mengembangkan model CNN dan LSTM untuk prakiraan anomali curah hujan dan kejadian hujan ekstrem dalam skala diperluas, dan menunjukkan bahwa model deep learning mampu memberikan prakiraan yang lebih andal untuk kejadian ekstrem tertentu. Penelitian terbaru yang menggunakan CNN untuk mengidentifikasi kejadian hujan ekstrem berdasarkan variabel dinamika atmosfer tertentu melaporkan bahwa model CNN dapat mengenali sekitar 95% kejadian hujan ekstrem yang diamati, dengan kinerja yang dinilai menggunakan metrik seperti area under ROC curve (AUC) (Mouassom et al., 2025).

Pada penelitian lain, studi terkait bahaya turunan dari kondisi curah hujan ekstrem, seperti prediksi kerentanan longsor dinamis akibat hujan ekstrem, menunjukkan bahwa arsitektur CNN 1D umum yang sering digunakan pada studi kerentanan berbasis hujan dapat ditingkatkan kinerjanya dengan optimasi struktur dan parameter, dan kinerja model diukur menggunakan metrik AUC (Mejia-Manrique et al., 2025). Rangkaian studi ini menegaskan bahwa CNN 1D dan varian *deep learning* terkait sangat relevan untuk tugas deteksi/klasifikasi kejadian berbasis deret waktu pada curah hujan dan indikator meteorologis lainnya.

Dalam penelitian ini, Autoencoder dan Convolutional Neural Network (CNN) memiliki fungsi yang berbeda namun saling melengkapi dalam proses analisis dan pemodelan curah hujan. Autoencoder merupakan metode unsupervised learning yang digunakan untuk mengekstraksi representasi laten dari data curah hujan historis. Melalui proses encoding dan decoding, Autoencoder mampu mereduksi dimensi data serta menangkap pola distribusi hujan yang kompleks dan nonlinier. Representasi laten yang dihasilkan kemudian digunakan untuk mengidentifikasi tipologi pola curah hujan tahunan yang memiliki karakteristik serupa.

Berbeda dengan Autoencoder, CNN satu dimensi dalam penelitian ini digunakan sebagai model prediksi yang memanfaatkan pola temporal dalam data curah hujan harian. CNN memiliki kemampuan dalam mengekstraksi fitur lokal dari data deret waktu sehingga dapat mengidentifikasi hubungan antara akumulasi curah hujan beberapa hari sebelumnya dengan kemungkinan terjadinya hujan lebat. Dengan demikian, CNN digunakan sebagai model klasifikasi atau prediksi probabilistik untuk mendeteksi kejadian hujan lebat.

Penggunaan kedua metode tersebut bersifat komplementer, di mana Autoencoder digunakan untuk memahami struktur dan pola dalam data curah hujan historis, sedangkan CNN digunakan untuk membangun model prediksi kejadian hujan lebat. Oleh karena itu, dalam penelitian ini Autoencoder dan CNN tidak digunakan sebagai metode yang dibandingkan, melainkan sebagai dua tahap pemodelan yang saling mendukung dalam proses analisis dan prediksi

2.1.5 Sintesis dan posisi penelitian

Dari kajian pustaka pada sub bab 2.1.1 sampai dengan 2.1.4 sebagaimana kami sajikan kembali pada Tabel 2.1, kami merangkum beberapa poin yang menjadi sintesis dan memposisikan penelitian ini berdasarkan penelitian terdahulu.

Tabel 2.1 Kajian penelitian terdahulu.

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
1	Chang et al. (2005)	Siklus tahunan hujan Asia Tenggara–Maritim	Analisis klimatologis & sirkulasi monsun	Asia Tenggara–Maritim	Mengidentifikasi perbedaan rezim hujan boreal summer vs boreal winter	Memberi konteks regional pola hujan monsun yang memengaruhi Serang
2	Sa’adi et al. (2021)	Penentuan zona iklim Borneo berbasis seasonality index	Analisis indeks musim & klustering	Pulau Borneo	Membagi rezim hujan menjadi 7 kelas berdasarkan indeks musim	Menunjukkan cara memampatkan pola tahunan menjadi tipologi rezim
3	Gunawan (2006)	Variabilitas atmosfer dan hujan di Sulawesi	Analisis deret waktu & klimatologis	Sulawesi, Indonesia	Menunjukkan pengaruh ENSO dan faktor lokal terhadap pola hujan	Menegaskan pentingnya informasi pola hujan lokal untuk sektor strategis
4	Basri et al. (2021)	Regionalisasi rezim hujan dengan hybrid RF–Bootstrap	Random Forest, Bootstrap, kluster hierarkis	Wilayah studi (multi-stasiun hujan)	Menghasilkan zonasi hujan homogen dengan galat (RMSE, MAE) yang menurun	Menjadi rujukan pemanfaatan klustering untuk rezim hujan
5	Suryanto (2017)	Pengelompokan curah hujan 15 harian di DIY	K-Means vs fuzzy c-means	Provinsi DI Yogyakarta	K-Means lebih sesuai untuk pola 15 harian dibanding fuzzy c-means	Menguatkan pemilihan K-Means + indeks validasi untuk klustering
6	Iskandar et al. (2025)	Tren dan variabilitas hujan (multi-stasiun)	Analisis deret waktu & statistik hujan	Beberapa stasiun hujan	Mengidentifikasi tren dan variabilitas curah hujan di bawah perubahan iklim	Memberi contoh analisis tren hujan yang bisa dikaitkan dengan tipologi lokal

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
7	Kurihana et al. (2024)	Identifikasi pola iklim dengan clustering autoencoder	Autoencoder + klustering	Data keluaran model iklim	AE menghasilkan representasi laten lebih informatif dari PCA untuk klaster iklim	Landasan penggunaan AE untuk tipologi rezim hujan tahunan
8	Ibebuchi (2024)	Klustering deret waktu fuzzy dengan Autoencoder	Autoencoder + fuzzy time series clustering	Deret waktu sirkulasi atmosfer	AE meningkatkan pemisahan klaster sirkulasi atmosfer	Menunjukkan keunggulan AE untuk klustering deret waktu
9	Spuler et al. (2025)	Rezim sirkulasi probabilistik terkait presipitasi ekstrem	Variational Autoencoder (VAE)	Data iklim & presipitasi lokal	VAE menghubungkan rezim sirkulasi dengan dampak hujan ekstrem lokal	Menginspirasi kaitan ruang laten dengan kejadian hujan ekstrem
10	Sari et al. (2020)	Prakiraan curah hujan harian hingga 14 hari	CNN 1D	Data observasi BMKG (Indonesia)	CNN 1D efektif menangkap pola temporal untuk prakiraan hujan harian	Landasan penggunaan CNN 1D pada deret waktu hujan di Indonesia
11	Ponnoprat (2021)	Prakiraan presipitasi harian dengan seasonally-integrated DL	Autoencoder + CNN/LSTM	Data presipitasi harian	Model DL mengungguli metode tradisional dalam akurasi prakiraan	Menunjukkan potensi kombinasi AE + CNN/LSTM untuk hujan
12	Liu et al. (2023)	Nowcasting level curah hujan dengan Conv1D-Transformer	Conv1D + Transformer (RLNformer)	Xinjiang Utara, Cina	Kombinasi Conv1D-Transformer efektif untuk klasifikasi level hujan	Menguatkan relevansi Conv1D untuk klasifikasi kategori hujan

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
13	Kim et al. (2020)	Prediksi cuaca laut global	Denoising AE + ConvLSTM	Data cuaca laut global	Penghilangan noise + pembelajaran spasio-temporal meningkatkan prakiraan	Menunjukkan manfaat AE + CNN/LSTM pada data atmosfer yang kompleks
14	Xie et al. (2023)	Prakiraan hujan dan kejadian ekstrem jangka menengah	Deep learning (CNN/LSTM)	Cina Timur	Model DL memberikan prakiraan yang cukup andal untuk kejadian hujan ekstrem	Rujukan penggunaan AUROC dalam menilai prakiraan kejadian ekstrem
15	Mariana et al. (2021)	Klaster hujan ekstrem dengan pendekatan robust	RPCA + Tukey's biweight + indeks validasi	Data hujan ekstrem	Menunjukkan pentingnya Silhouette, DBI, dan stabilitas klaster	Menginspirasi evaluasi kualitas–stabilitas klaster dalam penelitian ini
16	Gomyo & Kuraji, (2009)	Variasi spasial-temporal hujan dan hubungan ENSO di Sarawak, Malaysian Borneo.	Analisis korelasi SST–hujan + klastering Stasiun.	18 stasiun hujan di Sarawak.	Stasiun menjadi 4 klaster berdasarkan variasi fluktuasi musiman hujan; hubungan ENSO–hujan berbeda antarwilayah.	Menambah contoh regional maritim-tropis bahwa pola hujan lokal bisa dibedakan lewat klastering dan dipengaruhi penggerak iklim besar.
17	Machiwal et al., (2018)	Klastering stasiun hujan dan faktor pengontrol pola hujan.	PCA + Hierarchical Cluster Analysis.	62 stasiun, wilayah kering India barat, data 1957–2011.	HCA berhasil memetakan pola spasial hujan bulanan, musiman, dan tahunan antarstasiun.	Menguatkan penggunaan klastering untuk mengenali kemiripan pola hujan antarsatuan observasi.

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
18	Darand & Mansouri Daneshvar, (2014)	Regionalisasi rezim presipitasi.	PCA + Hierarchical Clustering Analysis.	Iran, dataset APHRODITE.	Menghasilkan 9 region presipitasi homogen dan menunjukkan HCA efektif untuk regionalisasi rezim.	Referensi kuat untuk pembentukan region/rezim homogen berbasis klastering.
19	Sahin & Kerem Cigizoglu, (2012)	Sub-climate regions dan sub-precipitation regime regions	Klastering /klasifikasi regional	Turki	Menunjukkan bahwa rezim presipitasi dapat dibedakan lebih rinci daripada pembagian iklim umum.	Mendukung gagasan bahwa tipologi hujan bisa dibangun sebagai produk yang lebih spesifik daripada klasifikasi iklim umum.
20	Gomes et al., (2018)	Identifikasi region presipitasi homogen	Fuzzy c-means + PBM index + H heterogeneity test	Tocantins – Araguaia, Brazilian Amazonia	Membentuk 3 region hujan homogen; validasi klaster dan homogenitas dilakukan eksplisit.	Menguatkan pentingnya validasi hasil klaster, bukan hanya membentuk klaster.
21	Chen et al., (2024)	Klastering siklus diurnal presipitasi	Hierarchical clustering	Estimasi satelit presipitasi global resolusi tinggi	Menunjukkan pola diurnal presipitasi global memiliki tipe-tipe berulang yang dapat dipisahkan lewat klastering.	Menambah bukti bahwa deret/pola presipitasi memang layak dipetakan ke tipologi melalui klastering.
22	Manco et al., (2026)	Pola berulang presipitasi ekstrem harian	K-means clustering	Semenanjung Italia, data/proyeksi resolusi tinggi	Mengidentifikasi pola spasio-temporal kejadian presipitasi	Menguatkan penggunaan klastering untuk pola kejadian ekstrem, bukan

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
					ekstrem harian dengan K-means.	hanya rata-rata klimatologis.
23	Nguyen & Quanz, (2021)	Pembelajaran representasi laten untuk peramalan deret waktu multivariat	Temporal Latent Auto-Encoder	Deret waktu multivariat	Mengembangkan latent auto-encoder untuk forecasting probabilistik deret waktu multivariat.	Penggunaan AE sebagai pembelajar representasi deret waktu.
24	Agarwal et al., (2024)	Deteksi ekstrem hujan	Spatially Regularized Graph Attention Autoencoder	Curah hujan spatio-temporal India 1990–2015	GAE dengan regularisasi spasial efektif mengidentifikasi pola hujan anomali/ekstrem dan menjaga koherensi geografis.	Memperkuat landasan bahwa autoencoder relevan bukan hanya untuk kompresi, tetapi juga untuk struktur dan anomali hujan.
25	Spuler et al., (2025)	Identifikasi weather regimes probabilistik yang ditargetkan pada presipitasi lokal	Variational Autoencoder (RMM-VAE)	Sirkulasi atmosfer dan target presipitasi lokal	VAE mampu menghasilkan rezim yang lebih prediktif terhadap variabel dampak lokal seperti presipitasi ekstrem.	Sangat dekat dengan ide ruang laten yang informatif terhadap kejadian hujan.
26	Texeira (2025)	Klastering pola presipitasi spatio-temporal	Deep convolutional autoencoder	Legal Amazon	Mengembangkan metode komputasional untuk mengekstraksi pola kompleks presipitasi	Penggunaan autoencoder untuk pola presipitasi.

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
					dari deret waktu.	
27	Akbari Asanjan et al., (2018)	Prakiraan presipitasi jangka pendek	LSTM recurrent neural networks	Sistem PERSIAN N	LSTM digunakan untuk short-term precipitation forecast berbasis sistem presipitasi satelit.	Studi ini memperkuat bahwa Deep Learning untuk deret waktu presipitasi dapat diterapkan.
28	Ashesh et al., (2022)	Quantitative precipitation nowcasting	Deep learning dengan attention/discriminator	Taiwan, horizon hingga 3 jam.	Model DL dikembangkan untuk nowcasting presipitasi resolusi tinggi dan diarahkan agar tetap akurat pada kejadian hujan tinggi.	Menunjukkan DL sesuai untuk tugas operasional hujan intens/kejadian signifikan.
29	Gorooh et al., (2022)	Estimasi presipitasi resolusi tinggi	CNN	Satelit	CNN dimanfaatkan untuk mengekstraksi fitur geospasial yang berkaitan dengan awan penghasil hujan.	Penggunaan CNN untuk masalah presipitasi, khususnya ekstraksi pola dari data kompleks.
30	Sadeghi et al., (2019)	Estimasi presipitasi dari penginderaan jauh	Convolutional Neural Network (PERSIANN-CNN)	Data penginderaan jauh/satelit	PERSIANN-CNN memberi estimasi hujan yang lebih akurat	CNN pada domain hujan memang punya performa deteksi/estimasi yang kuat.

No	Peneliti & Tahun	Fokus Penelitian	Metode / Model Utama	Lokasi / Data	Temuan Utama Singkat	Relevansi dengan Penelitian Ini
					daripada baseline	

1. Telah terdapat beberapa penelitian terdahulu yang kami temukan terkait dengan rezim curah hujan di wilayah Indonesia maupun Benua Maritim Indonesia, namun umumnya berfokus pada deskripsi pola musiman skala luas atau pembagian zona iklim berdasarkan indeks musim, bukan pada produk tipologi pola tahunan yang ringkas dan terdokumentasi di tingkat stasiun tunggal.
2. Pendekatan klastering curah hujan telah digunakan baik di Indonesia maupun di negara lain untuk mengelompokkan stasiun atau deret waktu curah hujan menjadi beberapa klaster homogen, dan berbagai indeks validasi klaster telah dievaluasi. Meski demikian, aspek stabilitas tipologi antartahun dan integrasinya dengan kebutuhan operasional di stasiun lokal masih relatif jarang dibahas.
3. Autoencoder dan variannya terbukti efektif sebagai alat reduksi dimensi dan pembelajaran representasi laten pada data iklim berdimensi tinggi, serta telah digunakan untuk mengidentifikasi rejim sirkulasi atau pola iklim yang terkait presipitasi. Namun, penerapan AE untuk membangun tipologi rezim hujan tahunan berbasis vektor dasarian pada satu stasiun hujan, dengan penilaian kualitas dan stabilitas tipologi secara eksplisit, masih sangat terbatas.
4. CNN 1D dan model deep learning sejenis telah dimanfaatkan secara luas untuk prakiraan curah hujan dan identifikasi kejadian hujan ekstrem. Sebagian besar penelitian berfokus pada prakiraan jumlah atau kelas curah hujan pada skala regional, atau pada penggunaan CNN untuk menilai bahaya hujan ekstrem yang luas, dengan metrik seperti

AUC, RMSE, dan MAE. Integrasi CNN 1D sebagai penyusun sinyal deteksi/indikasi dini hujan lebat yang dirancang khusus untuk kebutuhan produk di satu stasiun, dengan definisi ekstrem berbasis persentil musiman dan metrik operasional seperti POD, FAR, dan CSI, relatif belum banyak ditelaah.

Berdasarkan kesenjangan tersebut, penelitian ini menempatkan diri pada irisan antara pembentukan tipologi rezim hujan tahunan lokal dan pengembangan sinyal deteksi/indikasi dini hujan lebat berbasis CNN 1D pada tingkat stasiun. Kontribusi utama yang diharapkan adalah: (1) rancangan representasi tahunan berbasis dasarian yang dipelajari dengan Autoencoder untuk menghasilkan tipologi pola curah hujan tahunan yang berkualitas dan stabil pada stasiun tunggal; serta (2) pengembangan model CNN 1D berbasis jendela harian dengan definisi hujan lebat menggunakan persentil musiman, yang dievaluasi menggunakan metrik yang lazim pada sistem peringatan dini (POD, FAR, CSI, AUROC) dan diarahkan untuk mendukung kebutuhan layanan klimatologis di Stasiun Meteorologi Maritim Serang.

Berdasarkan tinjauan terhadap berbagai penelitian terdahulu, dapat disimpulkan bahwa analisis pola curah hujan dan pengembangan model prediksi hujan merupakan dua pendekatan yang saling melengkapi dalam studi klimatologi berbasis data. Penelitian mengenai pola hujan umumnya bertujuan untuk mengidentifikasi karakteristik distribusi hujan dalam suatu wilayah, sedangkan penelitian prediksi hujan berfokus pada pemanfaatan pola tersebut untuk memperkirakan kejadian hujan pada periode mendatang.

Beberapa penelitian telah menunjukkan bahwa metode pembelajaran representasi seperti Autoencoder mampu mengekstraksi fitur laten dari data iklim yang kompleks dan nonlinier sehingga memudahkan proses pengelompokan pola curah hujan. Di sisi lain, model deep learning seperti Convolutional Neural Network (CNN) telah terbukti efektif dalam mempelajari pola temporal dalam data deret waktu, termasuk dalam prediksi curah hujan harian dan kejadian hujan ekstrem.

Dalam konteks penelitian ini, kedua pendekatan tersebut digunakan secara komplementer. Analisis pengelompokan pola curah hujan tahunan digunakan untuk

memahami karakteristik rezim hujan lokal berdasarkan data historis, sedangkan model CNN 1D digunakan untuk memanfaatkan pola temporal jangka pendek dalam data curah hujan harian guna menghasilkan prediksi probabilistik kejadian hujan lebat.

Dengan demikian, posisi penelitian ini berada pada integrasi antara analisis pola curah hujan historis dan pemodelan prediksi berbasis deep learning, sehingga diharapkan dapat memberikan kontribusi baik dalam aspek pemahaman klimatologis maupun pengembangan sistem prediksi kejadian hujan lebat pada tingkat stasiun.

2.2 Landasan Teori

Subbab ini menguraikan konsep-konsep dasar yang menjadi fondasi penelitian, mencakup karakteristik curah hujan dan pola iklim di Indonesia, konsep rezim hujan dan representasi dasarian, prinsip pembelajaran representasi dengan Autoencoder, Convolutional Neural Network satu dimensi (CNN 1D) untuk deret waktu, serta teori mengenai klustering dan metrik verifikasi model deteksi hujan lebat.

Curah hujan merupakan salah satu unsur utama dalam klimatologi yang menggambarkan jumlah air yang jatuh ke permukaan bumi dalam bentuk hujan, biasanya dinyatakan dalam milimeter (mm) per satuan waktu (harian, dasarian, bulanan, dan seterusnya). Dalam konteks iklim tropis Indonesia, variasi utama iklim antarmusim lebih banyak tercermin dari variabilitas curah hujan dibandingkan suhu udara yang relatif konstan sepanjang tahun (Wilks, 2011).

Secara nasional, BMKG menjelaskan bahwa iklim Indonesia ditandai oleh tiga pola utama curah hujan, yaitu pola monsun, ekuatorial, dan lokal (BMKG, 2022). Pada pola monsun memiliki satu puncak musim hujan dan satu musim kemarau yang jelas, sangat dipengaruhi oleh sirkulasi angin monsun Asia–Australia. Sedangkan pola ekuatorial cenderung menunjukkan dua puncak musim hujan (bimodal) yang berkaitan dengan perlintasan Zona Konvergensi Antar Tropik (ITCZ) dua kali dalam setahun. Sementara pola lokal lebih kuat dipengaruhi topografi, morfologi pesisir, dan sirkulasi lokal, sehingga puncak hujan tidak selalu mengikuti pola monsun atau ekuatorial.

Pola curah hujan tahunan di suatu stasiun (rezim hujan) ditentukan oleh kombinasi faktor meteorologis skala besar dan lokal, antara lain sirkulasi monsun, posisi dan pergeseran ITCZ, fenomena laut-atmosfer skala besar seperti ENSO dan IOD, serta osilasi intramusiman seperti MJO (Mulsandi et al., 2023). Faktor lokal seperti topografi dan kedekatan dengan laut mengubah respon lokal terhadap sinyal-sinyal tersebut, sehingga tiap stasiun dapat memiliki karakter pola hujan tahunan yang berbeda meskipun berada pada zona iklim yang sama.

Dalam penelitian ini, curah hujan harian dipandang sebagai deret waktu klimatologis di satu stasiun. Data harian setiap baris mewakili satu tanggal (t) dengan nilai curah hujan harian $R(t)$ dalam mm. Untuk representasi dasarian data harian digabung menjadi 36 dasarian per tahun ($3 \text{ dasarian} \times 12 \text{ bulan}$) sehingga satu tahun direpresentasikan sebagai vektor $\mathbf{x}_{\text{tahun}} = [R_{D1}, R_{D2}, \dots, R_{D36}]$. Pendekatan agregasi ke skala 10 harian lazim digunakan dalam klimatologi operasional untuk memetakan pola musiman dan pergeseran musim hujan (BMKG, n.d.). Sedangkan rangkaian jendela harian merupakan data harian juga yang diturunkan menjadi akumulasi beberapa hari terakhir ($R_1, R_3, R_5, R_7, R_{10}$) untuk menangkap dinamika curah hujan jangka pendek yang relevan dengan kejadian hujan lebat dan ekstrem. Pendekatan jendela semacam ini sering digunakan dalam pemodelan hidrologi dan hujan-runoff (Wilks, 2011).

Dengan demikian, data curah hujan harian di Stasiun Meteorologi Maritim Serang dimanfaatkan untuk dua kebutuhan: (1) merangkum pola tahunan menjadi tipologi rezim hujan yang mudah dipahami, dan (2) menangkap dinamika hujan jangka pendek sebagai dasar deteksi hujan lebat harian.

Clustering adalah salah satu teknik *unsupervised learning* yang bertujuan mengelompokkan sekumpulan objek tanpa label ke dalam beberapa kelompok (cluster) sehingga objek dalam satu cluster relatif mirip, sedangkan objek antarkluster relatif berbeda. Teknik ini berguna untuk menemukan struktur atau pola tersembunyi pada data tanpa informasi target (Wilks, 2011).

Berbeda dengan *supervised learning* yang membutuhkan label, clustering hanya memanfaatkan fitur input. Algoritma berusaha menemukan partisi data ke dalam cluster-cluster yang memaksimalkan kemiripan intrakluster dan

meminimalkan perbedaan antarkluster, berdasarkan ukuran jarak atau kesamaan tertentu (misalnya jarak Euclidean atau kosinus).

1. **K-Means Clustering**

merupakan metode pengelompokan yang bekerja dengan asumsi jumlah cluster K telah ditentukan sebelumnya. Algoritma ini mengelompokkan data dengan cara meminimalkan jumlah kuadrat jarak setiap titik data terhadap centroid cluster masing-masing. Karena konsepnya sederhana dan komputasinya efisien, K-Means banyak digunakan dalam berbagai aplikasi analisis data, (Wilks, 2011).

2. **Hierarchical Clustering**

Menyusun struktur hierarki cluster dalam bentuk *dendrogram* dengan pendekatan *agglomerative* (penggabungan bottom-up) atau *divisive* (pemecahan top-down). Tidak memerlukan penentuan K di awal, karena jumlah cluster dapat dipilih dengan memotong dendrogram pada level tertentu (Wilks, 2011).

3. **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)**

Mengelompokkan titik berdasarkan kepadatan lokal dan mampu mengidentifikasi *noise*. Metode ini sangat sesuai untuk data dengan bentuk cluster tidak sferis atau memiliki variasi kepadatan

4. **Gaussian Mixture Model (GMM)**

Mengasumsikan data berasal dari campuran beberapa distribusi Gaussian, dan memberikan probabilitas keanggotaan tiap cluster (soft clustering) menggunakan algoritma EM. Dalam penelitian ini, fokus utama adalah penggunaan clustering (misalnya K-Means) pada **ruang laten Autoencoder** untuk membentuk tipologi rezim hujan tahunan.

Dalam Evaluasi Hasil Cluster ada beberapa indeks validasi internal yang umum digunakan adalah:

1. **Silhouette Score**

Diperkenalkan oleh Rousseeuw sebagai cara grafis dan numerik untuk menilai kualitas partisi cluster (Rousseeuw, 1987). Menggabungkan informasi jarak rata-rata ke cluster sendiri dan ke cluster tetangga terdekat; nilai rata-rata Silhouette mendekati 1 menandakan pemisahan cluster yang baik.

2. **Davies–Bouldin Index (DBI)**

Diperkenalkan oleh Davies dan Bouldin (1979) sebagai ukuran rata-rata “kemiripan terburuk” antarkluster berdasarkan rasio antara sebaran dalam cluster dan jarak antarcentroid. Nilai DBI yang lebih kecil menunjukkan pemisahan cluster yang lebih baik.

3. Calinski–Harabasz Index (CH Index)

Dikenal juga sebagai *variance ratio criterion*, dikembangkan oleh Caliński dan Harabasz (1974). Mengukur rasio dispersi antarcluster terhadap dispersi intracluster; nilai CH yang lebih besar mengindikasikan cluster yang lebih kompak dan terpisah.

Indeks-indeks ini digunakan dalam penelitian untuk memilih konfigurasi klaster yang paling sesuai dan menilai apakah tipologi rezim hujan tahunan yang diperoleh cukup baik secara geometris sebelum diinterpretasikan secara klimatologis.

2.2.1 Deep Learning

Deep learning merupakan cabang *machine learning* yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan untuk mempelajari representasi data pada berbagai tingkat abstraksi. Pendekatan ini telah secara luas digunakan di berbagai domain, termasuk pengenalan pola, pemrosesan citra, ucapan, serta analisis data ilmiah seperti genomik dan atmosfer (LeCun et al., 2015). Dalam penelitian ini digunakan dua arsitektur utama yaitu Autoencoder dan Convolutional Neural Network

2.2.3.1 Autoencoder

Autoencoder adalah jaringan saraf yang dilatih untuk merekonstruksi kembali input-nya sendiri, dengan struktur terdiri dari encoder dan decoder. Encoder memetakan vektor input $\mathbf{x} \in \mathbb{R}^d$ ke representasi laten berdimensi lebih rendah $\mathbf{z} \in \mathbb{R}^k$, sedangkan decoder mencoba merekonstruksi $\hat{\mathbf{x}}$ dari $\mathbf{z}$. Rumus matematika untuk Autoencoder dituliskan sebagaimana rumus 2.1 berikut.

$$\mathbf{z} = f_{\theta}(\mathbf{x}), \hat{\mathbf{x}} = g_{\phi}(\mathbf{z}) \dots\dots\dots (2.1)$$

Pelatihan dilakukan dengan meminimalkan *loss* rekonstruksi, misalnya MSE. Hinton dan Salakhutdinov menunjukkan bahwa *deep autoencoder* yang diinisialisasi dengan baik mampu menghasilkan kode berdimensi rendah yang lebih informatif dibanding PCA untuk berbagai jenis data berdimensi tinggi (Hinton et al., 2006).

Dalam penelitian ini, AE digunakan sebagai ekstraktor fitur tak terawasi untuk mempelajari representasi laten dari vektor 36-dasarian per tahun. Representasi laten tersebut kemudian menjadi dasar penerapan algoritma clustering untuk membentuk tipologi rezim hujan tahunan.

2.2.3.2 Convolutional Neural Network

Convolutional Neural Network menggunakan operasi konvolusi untuk mengekstraksi fitur lokal dari data. Walaupun banyak dikenal pada pengolahan citra (2D), CNN juga dapat diterapkan pada deret waktu satu dimensi (CNN 1D) dengan menggeser kernel konvolusi sepanjang sumbu waktu (LeCun et al., 2015).

Pada CNN 1D, kernel konvolusi berukuran kecil digeser melintasi deret input sehingga menghasilkan peta fitur yang merepresentasikan pola lokal (misalnya lonjakan curah hujan dalam beberapa hari terakhir). Studi-studi terkini menunjukkan bahwa CNN 1D efektif untuk pemodelan deret waktu meteorologi dan presipitasi, misalnya untuk prakiraan curah hujan dan klasifikasi kejadian hujan ekstrem (Wilks, 2011).

Dalam penelitian ini, CNN 1D digunakan untuk membangun model deteksi/indikasi dini hujan lebat harian berdasarkan rangkaian fitur R1, R3, R5, R7, dan R10 yang dirangkai sebagai input deret waktu.

2.2.2 Perpaduan Autoencoder dan Convolutional Neural Network

Perpaduan model dalam konteks penelitian ini merujuk pada pemanfaatan Autoencoder dan Convolutional Neural Network dalam satu kerangka analitis yang saling melengkapi, meskipun keduanya bekerja pada blok tujuan yang berbeda.

Pendekatan paduan yang menggabungkan *representation learning* tak terawasi (misalnya AE) dan *supervised learning* (misalnya CNN) telah banyak digunakan untuk meningkatkan kinerja dan interpretabilitas model pada data kompleks (LeCun et al., 2015).

Secara umum, kombinasi AE–CNN dapat dilakukan dengan:

1. Melatih AE untuk mengekstraksi representasi laten, lalu menggunakan representasi ini sebagai input model klasifikasi (misalnya CNN atau jaringan lain); atau
2. Menggunakan AE dan CNN dalam dua blok analisis yang berbeda namun saling mendukung: AE untuk merumuskan struktur atau rezim iklim, dan CNN untuk memprediksi atau mendeteksi kejadian ekstrem yang terkait.

Penelitian ini mengadopsi pendekatan kedua:


- Blok A (AE + clustering): Autoencoder digunakan untuk mereduksi dimensi pola hujan tahunan (36-dasarian) dan menghasilkan representasi laten yang kemudian dikluster menjadi tipologi rezim hujan tahunan.
- Blok B (CNN 1D): CNN 1D digunakan untuk mendeteksi kejadian hujan lebat harian berdasarkan rangkaian fitur akumulasi curah hujan beberapa hari terakhir.

Dengan demikian, seluruh kerangka analisis dapat dipandang sebagai model hybrid deep learning yang memadukan AE (untuk tipologi rezim tahunan) dan CNN 1D (untuk sinyal harian), yang bersama-sama memberikan gambaran dari skala tahunan hingga harian tentang perilaku curah hujan di stasiun.

2.3 Kerangka Pemikiran

Penelitian ini bertujuan menganalisis variabilitas curah hujan dan memprediksi kejadian hujan lebat menggunakan pendekatan berbasis data. Pola curah hujan tahunan direpresentasikan dalam data dasarian, kemudian dianalisis dengan Autoencoder untuk mengidentifikasi tipologi pola hujan yang serupa. Hasilnya digunakan dalam model prediksi probabilistik berbasis CNN 1D yang mempelajari pola temporal dari akumulasi hujan sebelumnya. Pendekatan ini diharapkan meningkatkan kemampuan prediksi hujan lebat di tingkat stasiun meteorologi.

Kerangka pemikiran untuk penelitian ini kami sajikan pada Gambar 2.1 berikut.



Gambar 2. 1 Kerangka pemikiran penelitian.

Gambar 2.1 menyajikan kerangka pemikiran dengan uraian sebagai berikut. Kerangka pemikiran penelitian ini berangkat dari fenomena bahwa curah hujan di wilayah maritim seperti Serang memiliki pola yang kompleks, dipengaruhi oleh interaksi monsun, ITCZ, fenomena laut-atmosfer (seperti ENSO dan IOD), serta faktor lokal seperti topografi dan kedekatan dengan laut. Kompleksitas ini membuat pola musim hujan-kemarau di tingkat stasiun tidak selalu mudah dibaca hanya dari tabel atau grafik curah hujan bulanan. Di sisi lain, Stasiun Meteorologi Maritim Kelas I Serang menyimpan deret waktu curah hujan harian yang panjang, tetapi belum tersedia ringkasan pola tahunan dan sinyal harian yang operasional untuk mendukung perencanaan infrastruktur dan kesiapsiagaan cuaca di kawasan pesisir.

Kondisi tersebut menjadi permasalahan utama: data historis yang kaya belum diolah menjadi informasi pola hujan yang ringkas dan mudah digunakan pemangku kepentingan.

Permasalahan ini menimbulkan kebutuhan untuk melakukan analisis pola curah hujan secara lebih sistematis melalui pengelompokan pola (clustering) sehingga dapat dibentuk tipologi rezim hujan tahunan di stasiun. Dengan merepresentasikan deret harian menjadi vektor 36-dasarian per tahun, tiap tahun pengamatan dapat diperlakukan sebagai satu objek yang akan dikelompokkan ke dalam beberapa pola tahunan yang relatif homogen. Pengelompokan ini diharapkan menghasilkan gambaran yang lebih eksplisit tentang tipe pola hujan di Serang (misalnya lebih mirip monsunial, ekuatorial, atau lokal), dinamika pergeserannya antar tahun, serta implikasinya terhadap musim tanam dan potensi kejadian hujan lebat. Selain pola tahunan, deret harian juga perlu dianalisis dalam bentuk jendela waktu pendek (R1, R3, R5, R7, R10) untuk mendeteksi kondisi yang mengarah pada hujan lebat, sehingga dibutuhkan model yang mampu mengenali pola deret waktu tersebut.

Dalam konteks itulah deep learning dipandang cocok untuk analisis pola curah hujan. Pendekatan ini memungkinkan pembelajaran representasi secara otomatis dari data berdimensi tinggi dan kompleks, tanpa harus merancang seluruh fitur secara manual. Autoencoder dapat mempelajari representasi laten (kode) dari pola hujan tahunan 36-dasarian, sedangkan Convolutional Neural Network (CNN) 1D mampu mengekstraksi pola lokal dari rangkaian akumulasi hujan harian (R1/R3/R5/R7/R10) yang berhubungan dengan kejadian hujan lebat. Dengan demikian, deep learning ditempatkan sebagai jembatan antara deret waktu curah hujan yang mentah dan informasi pola yang lebih mudah diinterpretasikan, baik di skala tahunan maupun harian.

Peran Autoencoder dalam kerangka ini adalah melakukan representasi, ekstraksi fitur, dan reduksi dimensi terhadap pola hujan tahunan. Vektor 36-dasarian tiap tahun dimasukkan ke dalam Autoencoder untuk dipelajari representasi latennya yang berdimensi lebih rendah, namun tetap memuat informasi pola utama. Ruang laten inilah yang kemudian menjadi dasar penerapan algoritma clustering (misalnya K-Means) untuk membentuk beberapa kelompok rezim hujan tahunan.

Sementara itu, peran CNN adalah mendeteksi kejadian hujan lebat harian. Deret waktu hujan harian diolah menjadi fitur jendela (R1, R3, R5, R7, R10) dan diberi label hujan lebat/tidak berdasarkan ambang persentil musiman (P95–P99). CNN 1D kemudian dilatih untuk mengenali pola jangka pendek yang membedakan hari-hari dengan hujan lebat dari hari-hari biasa, sehingga menghasilkan sinyal deteksi/indikasi dini di tingkat stasiun.

Tahap berikutnya adalah integrasi Autoencoder dan CNN dalam satu kerangka analitis. Di satu sisi, blok Autoencoder + clustering menghasilkan tipologi rezim hujan tahunan yang stabil dan dapat diinterpretasikan untuk menjelaskan variasi pola hujan antar tahun di Stasiun Meteorologi Maritim Serang. Di sisi lain, blok CNN 1D menghasilkan model deteksi hujan lebat harian yang dievaluasi dengan metrik POD, FAR, CSI, dan AUROC sehingga layak dipertimbangkan sebagai prototipe sinyal operasional. Integrasi kedua blok ini menghasilkan output penelitian berupa: (1) tipologi rezim hujan tahunan beserta tren kemunculannya yang dapat digunakan dalam komunikasi musim dan pengelolaan sumber daya air, dan (2) prototipe sinyal deteksi/indikasi dini hujan lebat harian yang sederhana dan siap dioperasikan di level stasiun. Selain memberikan manfaat praktis bagi stasiun, kerangka ini juga berkontribusi pada pengembangan aplikasi deep learning di bidang Teknik Informatika untuk analisis deret waktu curah hujan.

Kerangka pemikiran penelitian ini juga didasarkan pada pemahaman bahwa curah hujan merupakan fenomena atmosfer yang memiliki pola distribusi kompleks serta dipengaruhi oleh dinamika atmosfer regional maupun lokal. Analisis terhadap pola curah hujan historis dapat memberikan informasi penting mengenai karakteristik rezim hujan pada suatu wilayah, yang selanjutnya dapat dimanfaatkan sebagai dasar dalam pengembangan model prediksi kejadian hujan ekstrem.

Dalam penelitian ini, pendekatan yang digunakan mengintegrasikan dua metode pembelajaran mendalam, yaitu Autoencoder dan Convolutional Neural Network (CNN). Autoencoder digunakan untuk mengekstraksi representasi laten dari data curah hujan historis sehingga pola distribusi hujan tahunan yang memiliki karakteristik serupa dapat diidentifikasi dan dikelompokkan. Proses ini bertujuan untuk membentuk tipologi rezim hujan tahunan yang mencerminkan karakteristik klimatologis pada wilayah penelitian.

Selanjutnya, hasil analisis pola curah hujan historis dimanfaatkan sebagai dasar dalam pengembangan model prediksi kejadian hujan lebat harian. Model CNN 1D digunakan untuk mempelajari hubungan temporal dalam data curah hujan harian dengan memanfaatkan informasi akumulasi curah hujan beberapa hari sebelumnya. Melalui proses pelatihan model, CNN mampu mengidentifikasi pola temporal yang berkaitan dengan potensi kejadian hujan lebat.

Dengan pendekatan tersebut, penelitian ini tidak hanya berfokus pada analisis pola historis curah hujan, tetapi juga mengembangkan model prediksi probabilistik yang dapat digunakan untuk memperkirakan kemungkinan kejadian hujan lebat pada periode berikutnya. Integrasi antara analisis pola historis dan pemodelan prediktif ini diharapkan dapat memberikan kontribusi dalam pengembangan sistem prediksi hujan berbasis data pada tingkat stasiun meteorologi

BAB III

METODOLOGI PENELITIAN

Bab ini menjelaskan kebutuhan penelitian, rancangan teknis tahapan penelitian, serta teknik analisis dan evaluasi model yang digunakan untuk menjawab rumusan masalah terkait pembentukan tipologi rejim hujan tahunan dan pengembangan sinyal deteksi/indikasi dini hujan lebat di Stasiun Meteorologi Maritim Serang.

Dalam penelitian ini terdapat dua pendekatan analisis yang digunakan, yaitu analisis pola data dan pemodelan prediksi. Pada tahap pertama dilakukan analisis pola curah hujan tahunan menggunakan Autoencoder untuk mengekstraksi representasi laten dari data curah hujan historis. Representasi tersebut digunakan untuk mengidentifikasi kemiripan pola distribusi hujan sehingga dapat diperoleh tipologi pola curah hujan tahunan pada wilayah penelitian.

Tahap berikutnya adalah pembangunan model prediksi kejadian hujan lebat menggunakan Convolutional Neural Network (CNN) satu dimensi. Model ini memanfaatkan variabel input berupa akumulasi curah hujan beberapa hari sebelumnya sebagai fitur temporal untuk memprediksi kemungkinan kejadian hujan lebat pada hari berikutnya. Dalam konteks ini, CNN berfungsi sebagai model klasifikasi probabilistik yang membedakan antara kejadian hujan lebat dan tidak hujan lebat.

Dengan demikian, penelitian ini tidak hanya berfokus pada analisis pengelompokan pola curah hujan, tetapi juga mengarah pada pengembangan model prediksi kejadian hujan lebat berbasis pembelajaran mendalam. Pendekatan ini memungkinkan penelitian untuk memberikan kontribusi baik dalam pemahaman pola hujan historis maupun dalam pengembangan model prediksi berbasis data

3.1 Analisis Kebutuhan

Subbab ini menguraikan kebutuhan penelitian dari sisi dataset, atribut/fitur/label, populasi dan sampel, serta metode pengumpulan data.

3.1.1 Dataset dan sumber data

Data utama yang digunakan dalam penelitian ini adalah data curah hujan harian di Stasiun Meteorologi Maritim Kelas I Serang dengan periode pengamatan sekitar 30 tahun, yaitu dari 1995 hingga 2024. Data tersebut diperoleh dari arsip klimatologi internal BMKG (Stasiun Meteorologi Maritim Serang) yang telah melalui prosedur pencatatan operasional standar. Secara umum, struktur dataset harian dapat dinyatakan sebagai tanggal pengamatan (format: YYYY-MM-DD), dan untuk curah hujan harian (mm). Data bersifat deret waktu titik (station-based) sehingga setiap baris mewakili satu hari pengamatan di stasiun tersebut.

3.1.2 Atribut, Fitur, dan Label

Atribut dasar yang digunakan dalam penelitian ini berupa tanggal pengamatan (tahun, bulan, hari) dan curah hujan harian dalam satuan milimeter (mm). Data curah hujan kemudian diturunkan menjadi sejumlah fitur yang relevan untuk dua blok analisis sebagaimana telah kami sajikan pada Gambar 2.1, yaitu pembentukan tipologi rejim hujan tahunan (Blok A) dan pengembangan sinyal deteksi/indikasi dini hujan lebat harian (Blok B).

Untuk Blok A, fitur utama yang digunakan adalah akumulasi curah hujan per dasarian (10 harian). Dalam praktik klimatologi di Indonesia, dasarian digunakan sebagai satuan analisis yang menyeimbangkan kebutuhan resolusi temporal dengan peredaman fluktuasi harian. Satu tahun dibagi menjadi 36 dasarian ($3 \text{ dasarian} \times 12 \text{ bulan}$), sehingga pola curah hujan tahunan pada suatu stasiun dapat direpresentasikan sebagai vektor berdimensi 36 yang memuat akumulasi curah hujan pada masing-masing dasarian. Representasi seperti ini lazim digunakan dalam kajian pola hujan untuk mengidentifikasi rejim hujan tahunan dan pergeseran musim (BMKG, 2020a). Dalam blok ini, proses bersifat tak terawasi (unsupervised) sehingga tidak ada label eksternal; setiap tahun akan dikelompokkan ke dalam klaster berdasarkan kedekatan representasi laten yang dipelajari oleh Autoencoder.

Untuk Blok B, fitur difokuskan pada karakter deret waktu jangka pendek yang relevan dengan kejadian hujan lebat. Dari deret curah hujan harian, dibentuk fitur akumulasi jendela waktu seperti R1, R3, R5, R7, dan R10, yang masing-masing merepresentasikan jumlah curah hujan 1, 3, 5, 7, dan 10 hari terakhir hingga

hari ke- t . Pendekatan jendela seperti ini umum digunakan dalam model *time series* untuk curah hujan dan hidrologi karena mampu menangkap akumulasi hujan yang berperan pada kejadian ekstrem (Ishida et al., 2024).

Label (target) untuk Blok B berupa variabel biner yang menandai apakah terjadi kejadian hujan lebat pada hari ke- t atau tidak. Secara operasional, BMKG dan berbagai sumber merujuk klasifikasi intensitas hujan harian, misalnya hujan ringan (0,5–20 mm/hari), hujan sedang (20–50 mm/hari), dan hujan lebat ketika curah hujan harian melampaui sekitar 50 mm/hari. Pada penelitian ini, definisi kejadian hujan lebat dipertajam dengan pendekatan ambang persentil musiman, di mana hari-hari dengan curah hujan melebihi persentil ke-95 hingga ke-99 (P95–P99) dari distribusi hujan harian pada musim yang sama dikategorikan sebagai kejadian ekstrem. Pendefinisian ekstrem berbasis persentil banyak digunakan dalam studi iklim ekstrem karena lebih adaptif terhadap karakter lokal dan tidak bergantung pada satu nilai ambang absolut yang seragam (Wilks, 2011).

Dalam penelitian ini, permasalahan deteksi kejadian hujan lebat diformulasikan sebagai permasalahan **klasifikasi biner** (*binary classification*), di mana setiap observasi harian dikategorikan ke dalam dua kelas, yaitu kejadian hujan lebat dan tidak hujan lebat. Dengan demikian, model yang dibangun bertujuan untuk mempelajari hubungan antara fitur curah hujan beberapa hari sebelumnya dengan kemungkinan terjadinya hujan lebat pada hari berikutnya.

Secara formal, untuk setiap hari ke- t dengan fitur input berupa vektor akumulasi curah hujan ($R_1, R_3, R_5, R_7, R_{10}$), model mempelajari fungsi pemetaan dari ruang fitur ke probabilitas kejadian hujan lebat. Output model dinyatakan dalam bentuk probabilitas, yang merepresentasikan tingkat keyakinan bahwa pada hari ke- t terjadi hujan lebat. Nilai probabilitas ini selanjutnya dapat dikonversi menjadi keputusan klasifikasi menggunakan ambang tertentu, atau digunakan langsung sebagai sinyal probabilistik dalam konteks operasional.

Penentuan label kejadian hujan lebat dilakukan menggunakan pendekatan ambang berbasis persentil musiman, sehingga klasifikasi tidak bergantung pada satu nilai ambang absolut yang seragam untuk seluruh periode. Dengan pendekatan ini, hari dengan curah hujan yang melampaui persentil tinggi (misalnya P95 hingga P99) pada musim yang sama dikategorikan sebagai kejadian hujan lebat, sehingga

definisi kejadian ekstrem menjadi lebih adaptif terhadap karakteristik lokal dan variabilitas musiman.

Selain itu, permasalahan ini termasuk dalam kategori deteksi kejadian langka (*rare event classification*), karena kejadian hujan lebat relatif lebih jarang dibandingkan hari tanpa hujan lebat. Oleh karena itu, evaluasi model tidak hanya mempertimbangkan akurasi secara umum, tetapi juga menekankan kemampuan model dalam mendeteksi kejadian hujan lebat serta mengendalikan kesalahan prediksi, yang selanjutnya diukur menggunakan metrik seperti Probability of Detection (POD), False Alarm Ratio (FAR), dan Critical Success Index (CSI).

3.1.3 Populasi, Sampel, dan Teknik Sampling

Populasi konseptual penelitian ini adalah seluruh deret waktu curah hujan harian yang dapat diamati di Stasiun Meteorologi Maritim Serang sejak stasiun beroperasi hingga saat ini. Sampel penelitian dibatasi pada data curah hujan harian periode 1995–2024 yang tersedia dan memenuhi kriteria mutu dasar sebagaimana dijelaskan pada Subbab 3.1.4.

Untuk pembentukan tipologi rejim hujan tahunan, unit analisis adalah tahun, sehingga jumlah sampel setara dengan jumlah tahun pengamatan yang lolos seleksi mutu. Untuk pengembangan sinyal deteksi/indikasi dini hujan lebat, unit analisis adalah jendela deret waktu harian yang dibentuk dari kombinasi fitur R1, R3, R5, R7, dan R10 beserta label kejadian hujan lebat/tidak pada hari ke- t . Pendekatan ini sejalan dengan praktik umum pada pemodelan deret waktu curah hujan menggunakan *deep learning*, di mana setiap jendela deret waktu diperlakukan sebagai satu contoh pelatihan (training example) (Sari et al., 2020).

Teknik sampling yang digunakan untuk pemodelan CNN 1D adalah *time-aware split*, yaitu pemisahan data ke dalam data latih, validasi, dan uji berdasarkan periode waktu, bukan pemilihan acak murni. Pendekatan ini dianjurkan dalam pemodelan deret waktu agar informasi masa depan tidak tercampur ke proses pelatihan model (Wilks, 2011). Secara umum, penelitian ini menggunakan proporsi sekitar 60% data awal sebagai data latih, 20% periode berikutnya sebagai data validasi, dan 20% periode terakhir sebagai data uji, dengan tetap memperhatikan kecukupan jumlah kejadian hujan lebat di masing-masing himpunan.

3.1.4 Metode pengumpulan dan pra-pemrosesan data


Data curah hujan harian diperoleh dari arsip klimatologi Stasiun Meteorologi Maritim Serang/BMKG melalui prosedur ekstraksi data historis yang telah digunakan secara rutin dalam penyusunan informasi iklim. Tahapan pengumpulan meliputi penarikan data dari basis data internal atau file historis, pengecekan kesesuaian format tanggal dan satuan curah hujan (mm), serta verifikasi rentang waktu pengamatan. Praktik ini sejalan dengan pedoman penanganan data iklim yang menekankan pentingnya konsistensi format dan kelengkapan deret waktu sebelum digunakan untuk analisis statistik lanjutan.

Tahap pemeriksaan mutu (quality control) dilakukan untuk mengidentifikasi nilai yang tidak realistis (misalnya curah hujan negatif) dan hari dengan data hilang. Nilai ekstrem yang secara fisik tidak realistis dihapus atau dikoreksi berdasarkan catatan lapangan jika tersedia, sedangkan periode dengan data hilang yang cukup besar dapat dikecualikan dari analisis atau ditangani dengan metode imputasi yang sesuai, dengan tetap mencatat implikasinya terhadap hasil. Pendekatan serupa umum digunakan pada pemrosesan data meteorologi dan klimatologi sebelum dilakukan pemodelan statistik atau machine learning (Wilks, 2011).

Setelah lolos pemeriksaan mutu, data diolah menjadi dua bentuk utama: (1) vektor 36-dasarian per tahun untuk keperluan pembentukan tipologi rejim hujan tahunan; dan (2) jendela deret waktu harian (R1, R3, R5, R7, R10) beserta label hujan lebat/tidak untuk keperluan pemodelan CNN 1D. Fitur-fitur numerik kemudian dinormalisasi menggunakan skema yang sesuai (misalnya standar deviasi satuan atau min-max scaling) agar pelatihan Autoencoder dan CNN 1D menjadi lebih stabil (Hinton et al., 2006).

3.2 Perancangan Penelitian

Secara garis besar, alur penelitian dapat diringkas ke dalam tahapan berikut yang kami sajikan pada Gambar 3.1.



Gambar 3.1 Alur penelitian

Penjabaran dari Gambar 3.1 adalah sebagai berikut.

- a. Studi literatur dan identifikasi celah penelitian

Tahap awal penelitian dilakukan melalui studi literatur yang membahas rezim hujan, klastering curah hujan, Autoencoder, dan CNN (Bab II Subbab 2.1). ada tahap ini juga diidentifikasi celah penelitian, terutama keterbatasan studi sebelumnya yang belum banyak mengombinasikan Autoencoder untuk tipologi rezim hujan tahunan berbasis satu stasiun dengan CNN 1D untuk pendeteksian sinyal hujan lebat berbasis persentil musiman

b. Analisis kebutuhan dan pengumpulan data

Tahap ini mencakup penentuan kebutuhan dataset, fitur, dan label yang digunakan dalam penelitian (Subbab 3.1). Selanjutnya dilakukan pengumpulan serta pemeriksaan mutu data curah hujan harian periode 1995–2024 untuk memastikan kelayakan data sebelum digunakan pada tahap analisis berikutnya

c. Pra-pemrosesan dan pembentukan fitur

Data curah hujan yang telah melalui pengendalian mutu kemudian diproses untuk membentuk fitur penelitian. Hasil dari tahap ini berupa vektor 36-dasarian per tahun yang merepresentasikan pola hujan tahunan, serta fitur jendela akumulasi curah hujan R1–R10 yang dilengkapi dengan label kejadian hujan lebat dalam bentuk biner.

d. Pembangunan model tipologi rejim hujan tahunan (Blok A Gambar 2.1)

Pada tahap ini dilakukan perancangan dan pelatihan Autoencoder untuk mempelajari representasi laten dari vektor 36-dasarian. Representasi laten tersebut kemudian digunakan sebagai masukan dalam algoritma klastering, seperti K-Means, untuk membentuk tipologi rezim hujan tahunan. Kualitas dan stabilitas klaster dievaluasi menggunakan metrik Silhouette, Davies–Bouldin Index (DBI), serta Adjusted Rand Index (ARI) berbasis bootstrap, sebelum hasil klaster diinterpretasikan secara klimatologis.

e. Pembangunan model sinyal hujan lebat (Blok B Gambar 2.1)

Tahap ini berfokus pada penyusunan dataset berbasis jendela harian beserta label hujan lebat, dilanjutkan dengan perancangan dan pelatihan model CNN 1D. Kinerja model dievaluasi menggunakan metrik Probability of Detection (POD), False Alarm Ratio (FAR), Critical Success Index (CSI), dan Area Under the Receiver Operating Characteristic Curve (AUROC)

f. Analisis hasil dan rekomendasi

Tahap akhir penelitian dilakukan dengan mengaitkan tipologi rezim hujan yang dihasilkan dengan kondisi klimatologis lokal. Selain itu, dilakukan penilaian terhadap kelayakan sinyal hujan lebat sebagai dasar pengembangan produk klimatologis operasional di tingkat stasiun.

Metodologi penelitian ini dirancang untuk mengintegrasikan analisis pola curah hujan historis dengan pemodelan prediksi kejadian hujan lebat berbasis pembelajaran mendalam. Pendekatan ini dilakukan dalam dua tahapan utama.

Tahap pertama adalah analisis pola curah hujan tahunan menggunakan metode pembelajaran representasi berbasis Autoencoder. Pada tahap ini, data curah hujan harian diolah menjadi representasi dasarian sehingga setiap tahun direpresentasikan sebagai rangkaian distribusi curah hujan sepanjang 36 dasarian. Autoencoder digunakan untuk mengekstraksi fitur laten dari representasi tersebut sehingga pola distribusi curah hujan yang memiliki karakteristik serupa dapat diidentifikasi dan dikelompokkan.

Pengelompokan yang dilakukan dalam penelitian ini tidak didasarkan pada urutan waktu antar tahun, melainkan pada kemiripan pola distribusi curah hujan sepanjang tahun. Dengan demikian, dua tahun yang memiliki pola hujan serupa dapat berada dalam kelompok yang sama meskipun secara kronologis tidak berdekatan. Pendekatan ini bertujuan untuk mengidentifikasi tipologi rezim hujan tahunan yang mencerminkan karakteristik klimatologis lokal.

Tahap kedua penelitian difokuskan pada pengembangan model prediksi kejadian hujan lebat harian menggunakan Convolutional Neural Network satu dimensi (CNN 1D). Model ini memanfaatkan informasi curah hujan beberapa hari sebelumnya yang direpresentasikan dalam bentuk fitur akumulasi hujan pada berbagai jendela waktu, seperti akumulasi 1 hari, 3 hari, 5 hari, 7 hari, dan 10 hari terakhir. Fitur-fitur tersebut digunakan untuk menangkap dinamika temporal jangka pendek yang berpotensi memicu kejadian hujan lebat.

Model CNN 1D kemudian dilatih untuk mempelajari hubungan antara pola temporal curah hujan dan kejadian hujan lebat yang didefinisikan berdasarkan ambang persentil tertentu. Output dari model berupa probabilitas kejadian hujan

lebat pada suatu hari tertentu, sehingga model dapat digunakan sebagai sistem prediksi probabilistik berbasis data historis.

Dengan pendekatan ini, metodologi penelitian tidak hanya menghasilkan informasi mengenai pola curah hujan tahunan, tetapi juga menghasilkan model prediksi kejadian hujan lebat yang dapat dimanfaatkan dalam konteks operasional meteorologi pada tingkat stasiun.

Secara metodologis, penelitian ini terdiri dari dua pendekatan analisis. Tahap pertama adalah analisis pola curah hujan menggunakan Autoencoder yang termasuk dalam pendekatan pembelajaran tanpa label (unsupervised learning) untuk mengekstraksi representasi pola hujan historis. Tahap kedua adalah pembangunan model prediksi kejadian hujan lebat menggunakan CNN satu dimensi yang berfungsi sebagai model klasifikasi probabilistik. Dengan demikian, penelitian ini mengombinasikan analisis pola data dan pemodelan prediksi dalam satu kerangka penelitian

3.2.1 Rancangan teknis tipologi rejim hujan tahunan

Tahapan teknis tipologi rezim hujan tahunan secara lebih rinci adalah sebagai berikut.

1. Normalisasi data tahunan

Data curah hujan tahunan disusun dalam bentuk matriks $\mathbf{X} \in \mathbb{R}^{N \times 36}$, dengan N menyatakan jumlah tahun pengamatan dan 36 kolom merepresentasikan nilai curah hujan pada masing-masing dasarian. Selanjutnya, dilakukan proses normalisasi atau standardisasi agar setiap fitur dasarian berada pada skala yang sebanding, sehingga tidak terjadi dominasi fitur tertentu dalam proses pembelajaran model.

2. Perancangan dan pelatihan Autoencoder berdasarkan Hinton et al., (2006)

Autoencoder dirancang berdasarkan konsep yang diperkenalkan oleh Hinton et al. (2006) dengan arsitektur yang terdiri atas lapisan masukan berukuran 36, beberapa lapisan tersembunyi pada bagian encoder yang secara bertahap mereduksi dimensi hingga mencapai ruang laten berdimensi k (misalnya 2–8), serta bagian decoder yang bersifat simetris untuk merekonstruksi kembali vektor 36-dasarian. Fungsi aktivasi yang digunakan

disesuaikan dengan karakteristik data, seperti ReLU pada lapisan tersembunyi dan fungsi linear atau sigmoid pada lapisan keluaran, dengan fungsi loss rekonstruksi berupa mean squared error (MSE). Proses pelatihan dilakukan menggunakan metode optimisasi berbasis gradient descent, seperti Adam, hingga tercapai kondisi konvergen, dengan pemantauan nilai training loss dan validation loss untuk menghindari overfitting.

3. Ekstraksi representasi laten dan klustering

Setelah Autoencoder terlatih, keluaran dari bagian encoder diekstraksi sebagai representasi laten $\mathbf{Z} \in \mathbb{R}^{N \times k}$, yang merepresentasikan karakteristik utama pola hujan tahunan. Representasi laten ini selanjutnya digunakan sebagai masukan dalam proses klustering untuk membentuk tipologi rezim hujan tahunan.

4. Evaluasi kualitas dan stabilitas kluster

Evaluasi kualitas kluster dilakukan dengan menghitung indeks Silhouette dan Davies–Bouldin Index (DBI) untuk setiap konfigurasi jumlah kluster K . Selain itu, stabilitas kluster dinilai menggunakan prosedur bootstrap dengan cara mengambil sampel ulang dari tahun-tahun pengamatan, kemudian melakukan pelatihan ulang algoritma klustering pada setiap subset hasil bootstrap. Tingkat kesesuaian antara partisi kluster awal dan partisi hasil bootstrap diukur menggunakan Adjusted Rand Index (ARI) sebagai indikator kestabilan tipologi. Berdasarkan hasil evaluasi kualitas dan stabilitas tersebut, ditentukan kombinasi arsitektur Autoencoder dan metode klustering yang menghasilkan tipologi rezim hujan terbaik.

5. Interpretasi tipologi rejim hujan

Interpretasi tipologi rezim hujan dilakukan dengan menghitung nilai rata-rata vektor 36-dasarian pada setiap kluster sebagai representasi pola hujan khas. Pola dasar masing-masing kluster kemudian dianalisis untuk mengidentifikasi karakteristik utama rezim hujan, termasuk waktu awal musim hujan (onset), periode puncak curah hujan, serta pergeseran atau kemunduran musim hujan. Selanjutnya, disusun tipologi rezim hujan tahunan pada skala stasiun yang dilengkapi dengan contoh tahun-tahun

representatif untuk setiap klaster guna memperjelas interpretasi klimatologis

3.2.2 Rancangan Teknis Sinyal Deteksi/Indikasi Dini Hujan Lebat

Menggunakan CNN 1D berdasar penelitian-penelitian terdahulu (Ishida et al., 2024; Rasheeda Satheesh et al., 2025; Sari et al., 2020) sebagai berikut.

1. Penyusunan dataset jendela deret waktu

Penyusunan dataset dilakukan dengan membentuk deret nilai akumulasi curah hujan R1, R3, R5, R7, dan R10 untuk setiap hari pengamatan sebagai representasi kondisi hujan dalam beberapa rentang waktu sebelumnya. Selanjutnya, setiap hari diberi label kejadian hujan lebat atau tidak hujan lebat berdasarkan ambang persentil musiman yang telah ditetapkan. Fitur jendela dan label tersebut kemudian dipasangkan dan disusun dalam format yang sesuai untuk digunakan sebagai masukan pada model CNN 1D

2. Pembagian data

Data dibagi ke dalam himpunan latih, validasi, dan uji menggunakan skema berbasis waktu untuk menjaga konsistensi kronologis deret waktu dan menghindari kebocoran informasi. Dalam proses pembagian ini, diperhatikan agar proporsi kejadian hujan lebat pada masing-masing himpunan tetap memadai sehingga model dapat dilatih dan dievaluasi secara representatif

3. Pelatihan dan validasi model

Model CNN 1D dilatih menggunakan data latih dengan memanfaatkan data validasi untuk memantau proses pembelajaran. Selama pelatihan, nilai loss dan metrik kinerja utama, seperti Probability of Detection (POD), False Alarm Ratio (FAR), dan Critical Success Index (CSI), dievaluasi secara berkala. Untuk mencegah terjadinya overfitting, diterapkan mekanisme early stopping berdasarkan kinerja model pada data validasi.

4. Pengujian dan analisis model

Setelah proses pelatihan selesai, kinerja akhir model dievaluasi menggunakan data uji yang sepenuhnya independen. Evaluasi dilakukan dengan menghitung metrik POD, FAR, CSI, dan Area Under the Receiver Operating Characteristic Curve (AUROC). Jika diperlukan, hasil kinerja

model dibandingkan dengan metode baseline sederhana, seperti model berbasis aturan ambang, untuk menilai peningkatan performa yang diperoleh. Selain itu, dilakukan analisis pola kesalahan guna mengidentifikasi kondisi-kondisi di mana model cenderung mengalami miss atau menghasilkan false alarm.

5. Perancangan skema sinyal harian

3.2.3 Analisis dan evaluasi model

Indeks validasi kluster yang akan digunakan dalam penelitian ini adalah sebagai berikut:

a. Silhouette Coefficient:

Rata-rata $s(i)$ untuk seluruh titik digunakan sebagai nilai Silhouette keseluruhan. Interpretasi dari Koefisien Silhouette adalah semakin mendekati 1, pemisahan kluster semakin baik.

b. Davies–Bouldin Index (DBI):

Mengukur rata-rata kesamaan antar kluster berdasarkan rasio sebaran dalam kluster dan jarak antar centroid. Interpretasi dari DBI adalah semakin kecil nilai DBI, kualitas pemisahan kluster semakin baik.

c. Adjusted Rand Index (ARI):

Digunakan untuk menilai stabilitas kluster melalui perbandingan partisi kluster awal dengan partisi hasil *bootstrap*. Interpretasi dari ARI adalah sebagai berikut.

$ARI \approx 1 \rightarrow$ partisi sangat konsisten,

$ARI \approx 0 \rightarrow$ tidak lebih baik dari acak,

$ARI < 0 \rightarrow$ lebih buruk dari acak.

Pada tahap evaluasi model klasifikasi, pendekatan yang digunakan dalam penelitian ini didasarkan pada kerangka evaluasi model klasifikasi biner. Model Convolutional Neural Network (CNN) 1D yang dibangun bertujuan untuk mengklasifikasikan setiap observasi harian ke dalam dua kelas, yaitu kejadian hujan

lebat dan tidak hujan lebat. Oleh karena itu, evaluasi kinerja model dilakukan berdasarkan perbandingan antara hasil prediksi model dan kondisi observasi aktual.

Dalam konteks klasifikasi biner, hasil prediksi model dapat direpresentasikan dalam bentuk confusion matrix yang terdiri atas empat komponen utama, yaitu:

1. True Positive (TP): kejadian hujan lebat yang berhasil diprediksi dengan benar
2. False Positive (FP): prediksi hujan lebat yang tidak terjadi (false alarm)
3. False Negative (FN): kejadian hujan lebat yang tidak terdeteksi oleh model
4. True Negative (TN): kondisi tidak hujan lebat yang diprediksi dengan benar

Berdasarkan komponen confusion matrix tersebut, berbagai metrik evaluasi digunakan untuk menilai kinerja model secara lebih komprehensif, khususnya dalam konteks deteksi kejadian hujan lebat yang bersifat jarang (rare event). Metrik yang digunakan dalam penelitian ini meliputi Probability of Detection (POD), False Alarm Ratio (FAR), Critical Success Index (CSI), serta Area Under the Receiver Operating Characteristic Curve (AUROC). Dengan interpretasi semakin besar POD, semakin banyak kejadian ekstrem yang terdeteksi. Selain itu False Alarm Ratio (FAR), yang mengukur proporsi prediksi hujan lebat yang tidak terjadi. Dengan interpretasi semakin kecil FAR, semakin sedikit *false alarm*. Dan Critical Success Index (CSI). Menggabungkan informasi TP, FP, dan FN sekaligus. Interpretasi CSI adalah semakin besar CSI, semakin baik keseimbangan antara deteksi dan kesalahan.

- a. Probability of Detection (POD)

Mengukur proporsi kejadian hujan lebat yang berhasil dideteksi oleh model.

$$POD = \frac{TP}{TP + FN}$$

Semakin tinggi nilai POD, semakin baik kemampuan model dalam menangkap kejadian hujan lebat.

b. False Alarm Ratio (FAR)

Mengukur proporsi prediksi hujan lebat yang tidak terjadi.

$$FAR = \frac{FP}{TP + FP}$$

Semakin kecil nilai FAR, semakin sedikit kesalahan prediksi berupa false alarm.

c. Critical Success Index (CSI)

Mengukur keseimbangan antara keberhasilan deteksi dan kesalahan prediksi.

$$CSI = \frac{TP}{TP + FP + FN}$$

Semakin besar nilai CSI, semakin baik performa model secara keseluruhan dalam mendeteksi kejadian hujan lebat.

d. Area Under ROC Curve (AUROC)

AUROC mengukur kemampuan model dalam membedakan antara kelas hujan lebat dan tidak hujan lebat pada berbagai nilai ambang keputusan.

Interpretasi:

- AUROC $\approx 0,5$ $\rightarrow$ setara tebakan acak.
- AUROC $\rightarrow 1$ $\rightarrow$ kemampuan diskriminasi sangat baik.

3.3 Jadwal Penelitian

Jadwal rencana penelitian ini kami sajikan pada Tabel 3.1.

Tabel 3.1 Rencana jadwal penelitian.

No	Kegiatan Utama	B 1	B 2	B 3	B 4	B 5	B 6	B 7	B 8	B 9	B1 0	B1 1	B1 2
1	Identifikasi masalah	✓	✓										
2	Studi literatur		✓	✓									
3	Penyusunan metodologi			✓	✓								

No	Kegiatan Utama	B 1	B 2	B 3	B 4	B 5	B 6	B 7	B 8	B 9	B1 0	B1 1	B1 2
4	Seminar proposal				✓	✓							
5	Pengumpulan dan pemeriksaan data				✓	✓	✓						
6	Pengembangan dan pelatihan model Autoencoder (AE)					✓	✓	✓					
7	Klastering pada ruang laten dan evaluasi tipologi rejim hujan						✓	✓					
8	Pengembangan dan pelatihan model CNN 1D untuk sinyal hujan lebat							✓	✓				
9	Evaluasi kinerja CNN 1D (POD, FAR, CSI, AUROC), analisis kesalahan.								✓	✓			
10	Penyusunan Bab IV (Hasil dan Pembahasan)									✓	✓		
11	Penyusunan Bab V (Simpulan dan Saran)										✓	✓	
12	Seminar hasil, perbaikan akhir naskah, persiapan administrasi sidang tesis, sidang tesis, dan penyerahan tesis											✓	✓

DAFTAR PUSTAKA

- Agarwal, M., Das, P., & Bhatia, U. (2024). Spatially Regularized Graph Attention Autoencoder Framework for Detecting Rainfall Extremes. *ArXiv Preprint ArXiv:2411.07753*.
- Akbari Asanjan, A., Yang, T., Hsu, K., Sorooshian, S., Lin, J., & Peng, Q. (2018). Short-Term Precipitation Forecast Based on the PERSIANN System and LSTM Recurrent Neural Networks. *Journal of Geophysical Research: Atmospheres*, 123(22), 12,512-543,563. <https://doi.org/https://doi.org/10.1029/2018JD028375>
- Ashesh, A., Chang, C.-T., Chen, B.-F., Lin, H.-T., Chen, B., & Huang, T.-S. (2022). Accurate and Clear Quantitative Precipitation Nowcasting Based on a Deep Learning Model with Consecutive Attention and Rain-Map Discrimination. *Artificial Intelligence for the Earth Systems*, 1(3), e210005. <https://doi.org/https://doi.org/10.1175/AIES-D-21-0005.1>
- Basri, M. A., Shaharudin, S. M., Kismiantini, Tan, M. L., Mohd Najib, S. A., Zainuddin, N. H., & Andayani, S. (2021). Regionalization of Rainfall Regimes Using Hybrid RF-Bs Couple with Multivariate Approaches. In *ISPRS International Journal of Geo-Information* (Vol. 10, Issue 10). <https://doi.org/10.3390/ijgi10100689>
- BMKG. (n.d.). *Climate Variability of Indonesia*. <https://iklim.bmkg.go.id/publikasi-klimat/ftp/brosur/LEAFLETINGGRISB.pdf>
- BMKG. (2016). *Peraturan Kepala BMKG Nomor 4 Tahun 2016 Tentang Pengamatan dan Pengelolaan Data Iklim di Lingkungan BMKG*. BMKG.
- BMKG. (2020a). *Buletin Stasiun Meteorologi Umbu Mehang Kunda*. https://ntt.bmkg.go.id/uploads/buletin/2020/06/buletin_Juni_2020.pdf
- BMKG. (2020b). *Peraturan Badan Meteorologi, Klimatologi, dan Geofisika Republik Indonesia Nomor 4 Tahun 2020 Tentang Rencana Strategis Badan Meteorologi, Klimatologi, dan Geofisika Tahun 2020—2024*.
- BMKG. (2022). *Pemutakhiran Zona Musim Indonesia Periode 1991 -- 2020*. BMKG.
- Chang, C.-P., Wang, Z., McBride, J., & Liu, C.-H. (2005). Annual Cycle of Southeast Asia—Maritime Continent Rainfall and the Asymmetric Monsoon Transition. *Journal of Climate*, 18(2), 287–301. <https://doi.org/https://doi.org/10.1175/JCLI-3257.1>
- Chen, P., Chen, A., Yin, S., Li, Y., & Liu, J. (2024). Clustering the Diurnal Cycle of Precipitation Using Global Satellite Data. *Geophysical Research Letters*, 51(23), e2024GL111513. <https://doi.org/https://doi.org/10.1029/2024GL111513>

- Darand, M., & Mansouri Daneshvar, M. R. (2014). Regionalization of Precipitation Regimes in Iran Using Principal Component Analysis and Hierarchical Clustering Analysis. *Environmental Processes*, 1(4), 517–532. <https://doi.org/10.1007/s40710-014-0039-1>
- Gomes, E. P., Blanco, C. J. C., & Pessoa, F. C. L. (2018). Identification of homogeneous precipitation regions via Fuzzy c-means in the hydrographic region of Tocantins–Araguaia of Brazilian Amazonia. *Applied Water Science*, 9(1), 6. <https://doi.org/10.1007/s13201-018-0884-6>
- Gomyo, M., & Kuraji, K. (2009). Spatial and Temporal Variations in Rainfall and the ENSO-rainfall Relationship over Sarawak, Malaysian Borneo. *SOLA*, 5, 41–44. <https://doi.org/10.2151/sola.2009-011>
- Gorooh, V. A., Asanjan, A. A., Nguyen, P., Hsu, K., & Sorooshian, S. (2022). Deep Neural Network High Spatiotemporal Resolution Precipitation Estimation (Deep-STEP) Using Passive Microwave and Infrared Data. *Journal of Hydrometeorology*, 23(4), 597–617. <https://doi.org/https://doi.org/10.1175/JHM-D-21-0194.1>
- Gunawan, D. (2006). *Atmospheric Variability in Sulawesi, Indonesia*.
- Hermawan, E., Risyanto, R., Purwaningsih, A., Ratri, D. N., Ridho, A., Harjana, T., Andarini, D. F., Satyawardhana, H., & Sujalu, A. P. (2025). Characteristics of Mesoscale Convective Systems and Their Impact on Heavy Rainfall in Indonesia's New Capital City, Nusantara, in March 2022. *Advances in Atmospheric Sciences*, 42(2), 342–356. <https://doi.org/10.1007/s00376-024-4102-1>
- Hinton, G., Salakhutdinov, R., & Rachmad, Y. (2006). Reducing the Dimensionality of Data with Neural Networks. *Science (New York, N.Y.)*, 313, 504–507. <https://doi.org/10.1126/science.1127647>
- Ibebuchi, C. C. (2024). Fuzzy time series clustering using autoencoders neural network. *AIMS Geosciences*, 10(3), 524–539. <https://doi.org/10.3934/geosci.2024027>
- Ishida, K., Ercan, A., Nagasato, T., Kiyama, M., & Amagasaki, M. (2024). Use of one-dimensional CNN for input data size reduction in LSTM for improved computational efficiency and accuracy in hourly rainfall-runoff modeling. *Journal of Environmental Management*, 359, 120931. <https://doi.org/https://doi.org/10.1016/j.jenvman.2024.120931>
- Iskandar, M. F., Ibrahim, A., Mohtar, Z. A., Pakir Mohamed Latif, M. F., & EM Yahaya, N. K. (2025). Assessing rainfall trends and variability in a climate change. *ESTEEM Academic Journal*, 21, 91–105.
- Kim, K.-S., Lee, J.-B., Roh, M.-I., Han, K.-M., & Lee, G.-H. (2020). Prediction of ocean weather based on denoising autoencoder and convolutional LSTM. *Journal of Marine Science and Engineering*, 8(10), 805.
- Kurihana, T., Mastilovic, I., Wang, L., Meray, A., Praveen, S., Xu, Z.,

- Memarzadeh, M., Lavin, A., & Wainwright, H. (2024). Identifying Climate Patterns Using Clustering Autoencoder Techniques. *Artificial Intelligence for the Earth Systems*, 3(3), e230035. <https://doi.org/https://doi.org/10.1175/AIES-D-23-0035.1>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Liu, Y., Liu, S., & Chen, J. (2023). RLNformer: A Rainfall Levels Nowcasting Model Based on Conv1D Transformer for the Northern Xinjiang Area of China. *Water*, 15(20), 3650.
- Machiwal, D., Kumar, S., Meena, H. M., Santra, P., Singh, R., & Singh, D. (2018). Clustering of Rainfall Stations and Distinguishing Influential Factors using PCA and HCA Techniques over Western Dry Region of India. *Meteorological Applications*. <https://doi.org/10.1002/met.1763>
- Mahmoud, W. H., Elagib, N. A., Gaese, H., & Heinrich, J. (2014). Rainfall conditions and rainwater harvesting potential in the urban area of Khartoum. *Resources, Conservation and Recycling*, 91, 89–99. <https://doi.org/https://doi.org/10.1016/j.resconrec.2014.07.014>
- Manco, I., Feitosa, O. M., Raffa, M., Schiano, P., Rianna, G., & Mercogliano, P. (2026). Identifying recurring patterns of extreme daily precipitation using K-means algorithm: Uncovering spatial shift driven by climate change over the Italian Peninsula. *Weather and Climate Extremes*, 51, 100849. <https://doi.org/https://doi.org/10.1016/j.wace.2025.100849>
- Mariana, S., Nor, C., Shaharudin, S., Ismail, S., & Kismiantini. (2021). A RPCA-Based Tukey's Biweight for Clustering Identification on Extreme Rainfall Data. *Environment and Ecology Research*, 12, 114–118. <https://doi.org/10.13189/eer.2021.090303>
- Mejia-Manrique, S. A., Ramos-Scharrón, C. E., Hughes, K. S., Gonzalez-Cruz, J. E., & Khanbilvardi, R. M. (2025). Dynamic landslide susceptibility for extreme rainfall events using an optimized convolutional neural network approach. *Natural Hazards*, 1–29.
- Mouassom, F. L., Tamoffo, A. T., & Cardoso-Bihlo, E. (2025). Convolutional Neural Network-Based Insights Into Extreme Precipitation Regional Dynamics Over Central Africa Using Moisture Flux Patterns. *Journal of Geophysical Research: Atmospheres*, 130(16), e2025JD044341. <https://doi.org/https://doi.org/10.1029/2025JD044341>
- Mulsandi, A., Koesmaryono, Y., Hidayat, R., Faqih, A., & Sopaheluwakan, A. (2023). On The Interannual Variability of Indonesian Monsoon Rainfall (IMR): A Literature Review of The Role of its External Forcing. *Jurnal Meteorologi Dan Geofisika*, 24(2), 115–127.
- Nguyen, N., & Quanz, B. (2021). Temporal latent auto-encoder: A method for probabilistic multivariate time series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(10), 9117–9125.

- Ponnoprat, D. (2021). Short-term daily precipitation forecasting with seasonally-integrated autoencoder. *Applied Soft Computing*, 102, 107083.
- Rasheeda Satheesh, A., Knippertz, P., & Fink, A. H. (2025). Machine learning models for daily rainfall forecasting in Northern Tropical Africa using tropical wave predictors. *Weather and Forecasting*, 40(10), 1895–1916.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/https://doi.org/10.1016/0377-0427(87)90125-7)
- Sa'adi, Z., Shahid, S., & Shiru, M. S. (2021). Defining Climate Zone of Borneo based on Cluster Analysis. *Theoretical and Applied Climatology*. <https://doi.org/https://doi.org/10.21203/rs.3.rs-283015/v1>
- Sadeghi, M., Asanjan, A. A., Faridzad, M., Nguyen, P., Hsu, K., Sorooshian, S., & Braithwaite, D. (2019). PERSIANN-CNN: Precipitation Estimation from Remotely Sensed Information Using Artificial Neural Networks–Convolutional Neural Networks. *Journal of Hydrometeorology*, 20(12), 2273–2289. <https://doi.org/https://doi.org/10.1175/JHM-D-19-0110.1>
- Sahin, S., & Kerem Cigizoglu, H. (2012). The sub-climate regions and the sub-precipitation regime regions in Turkey. *Journal of Hydrology*, 450–451, 180–189. <https://doi.org/https://doi.org/10.1016/j.jhydrol.2012.04.062>
- Sari, Y., Djarnal, E., & Nugraha, F. (2020). *Daily Rainfall Prediction Using One Dimensional Convolutional Neural Networks*. <https://doi.org/10.1109/IC2IE50715.2020.9274572>
- Spuler, F. R., Kretschmer, M., Balmaseda, M. A., Kovalchuk, Y., & Shepherd, T. G. (2025). Learning predictable and informative dynamical drivers of extreme precipitation using variational autoencoders. *Weather and Climate Dynamics*, 6(3), 995–1014. <https://doi.org/10.5194/wcd-6-995-2025>
- Steward, B. (WMO). (2011). Managing Water Resources with Climate Information. *WMO Vol 60 (2)*. <https://wmo.int/resources/magazines/vol-60-2-2011>
- Suryanto, J. (2017). *ANALISA PERBANDINGAN PENGELOMPOKKAN CURAH HUJAN 15 HARIAN PROVINSI DIY MENGGUNAKAN FUZZY CLUSTERING DAN K-MEANS CLUSTERING*. XVI, 229–242. <https://doi.org/10.31293/af.v16i2.2905>
- Texeira, R. B. (2025). Clustering of spatio-temporal precipitation patterns in the Legal Amazon using deep convolutional autoencoder. *Ciência e Natura*, 47, e85042–e85042.
- Wilks, D. S. (2011). *Statistical methods in the atmospheric sciences* (Vol. 100). Academic press.
- Winarto, Y. T. ., Stigter, C. J. ., & Wicaksono, M. K. (2017). Transdisciplinary

Responses to Climate Change: Institutionalizing Agrometeorological Learning Through Science Field Shops in Indonesia. *Gender, Ethnicity, and Environmental Transformations*, 10(1).
<https://doi.org/https://doi.org/10.14764/10.ASEAS-2017.1-5>

Xie, J., Hsu, P.-C., Hu, Y., Ye, M., & Yu, J. (2023). Skillful extended-range forecast of rainfall and extreme events in East China based on deep learning. *Weather and Forecasting*, 38(3), 467–486.